Pokročilé informační systémy

Business intelligence a OLAP

prof. Ing. Tomáš Hruška, CSc.
doc. Ing. Radek Burget, Ph.D.
burgetr@fit.vut.cz

Business Intelligence

Motivace a základní pojmy

Data, informace, znalosti – shrnutí

- **Data** – hodnoty bez sémantiky, reprezentují *stav* systému
- **Informace** – interpretovaná data (interpretaci provádí uživatel nebo systém)
- **Znalosti** – informace zařazené do kontextu, *sekundární odvozené informace*
  - Získávány agregací a analýzou (nad **velkými daty**)
- Některé IS pracují s daty transakčně (**OLTP**), jiné generují znalosti pro rozhodování (**OLAP**)

Pyramidové schéma informačních systémů

Motivace

- Manager potřebuje vědět:
  - Kterým klientům lze nabídnout úvěrovou kartu?
  - U kterých klientů je vysoké riziko odchodu ke konkurenci?
  - Jak se vyvíjejí tržby za posledních 30 dní v členění dle regionů a produktů?
  - Jak se liší skutečný výkon od plánovaného?
- Klasická transakční (OLTP) databáze na tyto otázky **neumí efektivně odpovědět**

Business Intelligence

- Procesy, technologie a nástroje potřebné k **přetvoření dat a informací do znalostí** pro podporu rozhodování
- **Vstup**: velké objemy (big data) primárních produkčních dat
- **Výstup**: znalosti využitelné v procesu rozhodování na různých úrovních řízení

Prostředky Business Intelligence

- **Datové sklady** (*data warehouses*)
  - Systém převodu a uložení dat pro analýzu
  - Definují formální model dat
- **OLAP** (*On-line Analytical Processing*)
  - Rozhraní pro manipulaci s modelem a zpřístupnění výsledků
- **Data Mining** (dolování dat)
  - Viz specializovaný kurz *Získávání znalostí z databází* (ZZN)

Datové sklady

Data Warehouses

Pojem datového skladu

- Podnikově strukturovaný depozitář **subjektově orientovaných, integrovaných, časově proměnlivých, historických dat** použitých pro získávání *znalostí* a podporu rozhodování
- Obsahuje operační i agregovaná data

Datový sklad – technologie

- Technologie zajišťující:
  - **Natažení** (extrakce a transformace),
  - **Uložení** (*loading*) a
  - **Poskytování** dat
- Pro **podporu rozhodování prováděnou analýzou informací** a vytvářením *znalostí*
- Provozován **odděleně** od základní **operační (produkční) databáze**

Nevhodnost produkčních databází pro analýzu

- Navrženy pro **ukládání detailních dat** v izomorfním modelu
- Výsledkem jsou zpravidla data explicitně uložená – bez agregačních úprav
- Vhodné pro **jednoduché transakce** (OLTP), nevhodné pro **složitější analýzu velkých dat**

Nevhodnost produkčních databází – pokračování

- **Decentralizovanost** OLTP systémů
  - Data pro analýzu jsou uložena v **různých heterogenních DB na různých serverech**
  - Není k dispozici integrovaný zdroj
- **Nehomogenní struktura** – různé názvy atributů, datové typy
- **Degradace výkonu** opakovanými agregačními výpočty
- Zpravidla uchovávají **pouze aktuální data** – chybí historická data

Vhodný model – vícerozměrnost

- Pro komplexní analýzu a vizualizaci jsou data v datovém skladu modelována **multidimenzionálně**
- Jiný datový model, než relační
- Klade důraz na **strukturu vhodnou pro ad hoc dotazy** vyžadující agregační a statistické výpočty

Multidimenzionální databáze

- Platforma pro získání **agregovaných údajů**
- Výpočty, které by se opakovaně prováděly, mohou být **spočteny předem a uloženy (materializovány)** pro rychlý přístup
- Redundance zde není podstatný problém:
  - Data jsou **read-only**
  - Nevzniká problém udržování konzistence a vícenásobného přístupu

Architektura datového skladu

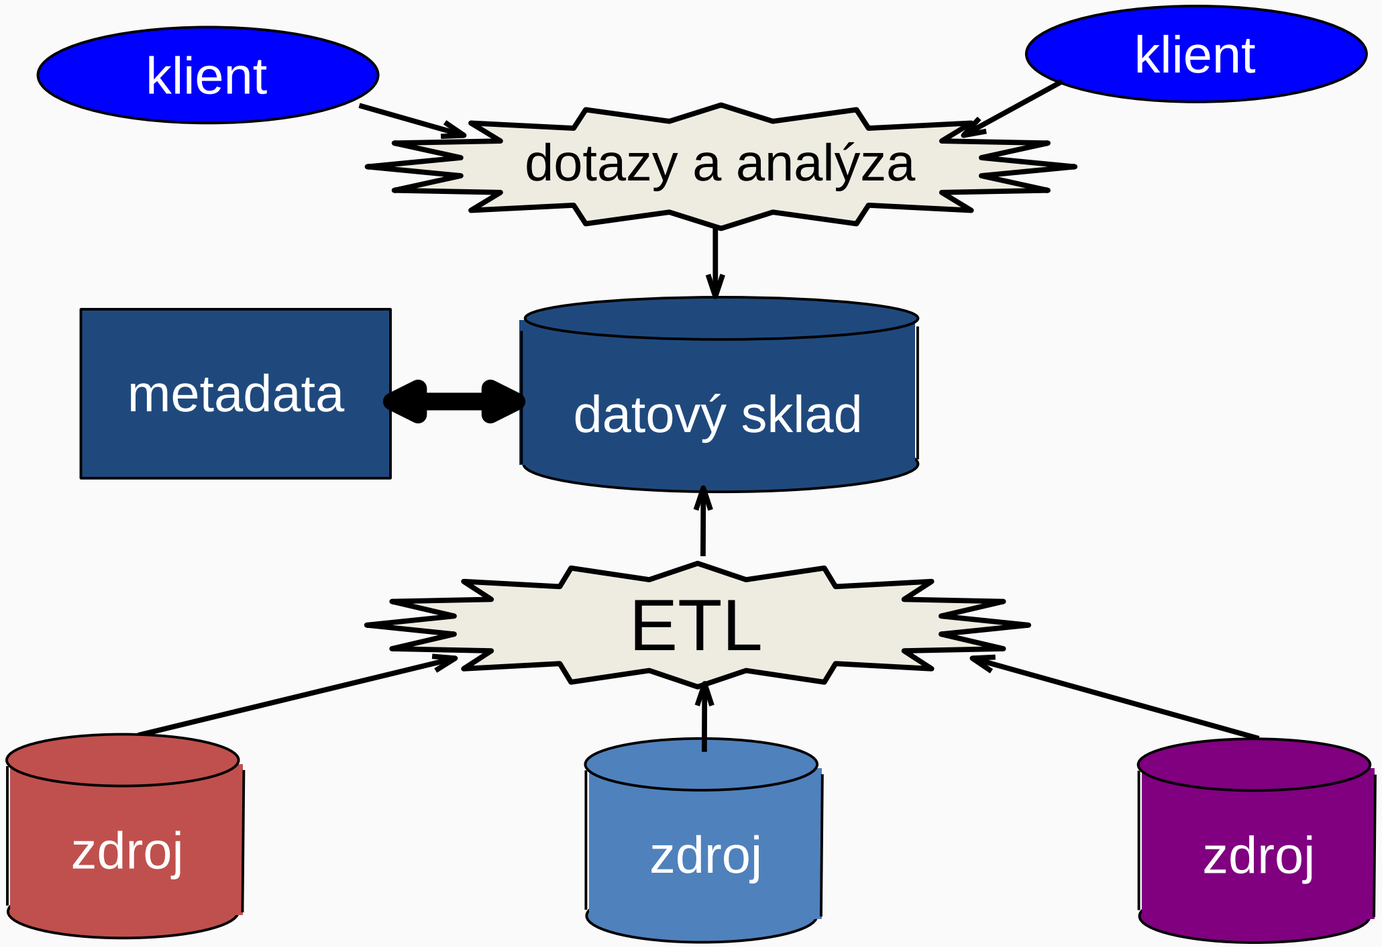

Architektura datového skladu – 3 části

1. **Získání dat**
   - Zdrojová data + místo přípravy (*ETL*: Extraction, Transformation, Loading)
2. **Uložení dat**
   - Datový sklad + datové trhy + uložení metadat
   - Navrženo *pro analýzu*, read-only
3. **Předávání výsledků**
   - OLAP, dotazovací nástroje, generátory zpráv, data mining

Vlastnosti datového skladu

- **Orientace podle subjektu** – fakta organizována podle průsečíků n-dimenzí
- **Integrace** – data z různých zdrojů ukládána *jednotně jednou*
  - Jednotná terminologie, jednotky veličin
  - Nutnost úpravy, vyčistění a sjednocení vstupních dat
- **Časová proměnlivost** – každý klíč obsahuje čas (explicitně nebo implicitně)
  - Historický horizont: typicky 5–10 let (vs. aktuální data v OLTP)
- **Neměnnost** – v datovém skladu se data *nemění*
  - Pouze dvě operace: **vkládání** a **čtení**
  - Nepotřebuje zpracování transakcí ani mechanismy souběžného přístupu

Produkční databáze vs. datový sklad

Vlastnost	Produkční DB (OLTP)	Datový sklad (OLAP)
Uživatelé	Běžní pracovníci	Manažeři, analytici
Data	Aktuální, detailní	Historická, sloučená
Model	ER + aplikace	Multidimenzionální kostka
Pohled na data	Aktuální, lokální	Agregovaný
Přístup	Aktualizace	Read-only, komplexní dotazy

Shrnutí požadavků na datový sklad

- Schopnost **agregace**
- Databáze navržená pro **analytické dotazy**
- Možnost **integrovat data** z více aplikací
- Převažuje operace **čtení**
- **Periodické** doplňování dat
- Možnost využití **současných i historických dat**

Multidimenzionální model

Dimenze, fakta, kostka

Dimenze

- **Dimenze** je *uspořádatelná* množina hodnot *diskrétního* základního typu (integer, výčet, čas) nebo množina jejich struktur **hierarchicky organizovaných**
- Příklady dimenzí:
  - **Čas**: leden, únor, ..., prosinec (nebo rok → kvartál → měsíc → den)
  - **Místo**: Praha, Brno, Ostrava, Plzeň, ... (nebo kontinent → země → město)
  - **Produkt**: kabáty, kalhoty, bundy, čepice, trička, ...

Příklady dimenzí

Množina dimenzí

- Nechť existuje **uspořádaná** množina n dimenzí $\{D_1, D_2, D_3, \ldots, D_n\}$
  - tj. existuje **relace uspořádání** R ($<$) nad množinou dimenzí
- Počet různých uspořádání je $n!$ (počet **permutací** nad n prvky).
  - Je to také počet stěn *n*-dimenzionální kostky. Například *3D* kostka má 6 stěn, ale *2D* čtverec má 4 stěny (strany).

1	čas	produkt	místo
2	čas	místo	produkt
3	produkt	čas	místo

4	produkt	místo	čas
5	místo	produkt	čas
6	místo	čas	produkt

Aktivní dimenze

- Nechť existuje uspořádaná podmnožina **aktivních dimenzí** $\{A_1, A_2, \ldots, A_m\}$ $(m \leq n)$
- Aktivní dimenze budou uspořádány stejně jako v původní množině všech dimenzí

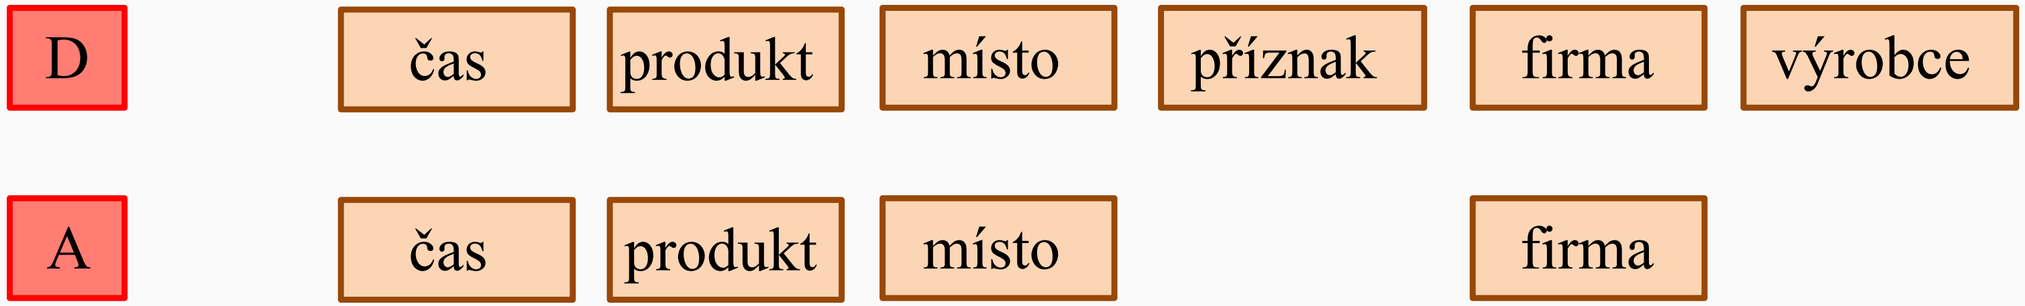

Definice multidimenzionální kostky

- **Multidimenzionální kostka** je funkce:

$$g_m : (A_1 \times A_2 \times A_3 \times \cdots \times A_m) \rightarrow F$$

  kde $\{A_1, A_2, \ldots, A_m\}$ je uspořádaná podmnožina **aktivních dimenzí** a F je množina faktů.

- Prvky F nazýváme **fakty (míry, *measures*)**

$$g_m(a_1, a_2, \ldots, a_m) \in F$$

  kde $a_i \in A_i$

Fakt (míra, measure)

- **Fakt** je libovolná **agregovatelná** hodnota (lze ji sčítat, průměrovat, apod.)
- Příklady faktů:
  - Počet prodaných kusů
  - Tržba v Kč
  - Průměrná cena
- Výsledkem jsou kostky *počtů*, *součtů*, *průměrů* apod.
- Fakta jsou organizována na průsečících hodnot dimenzí

3D kostka – příklad

- Dimenze: **čas** × **produkt** × **region**
- Na každém průsečíku je uložen (nebo vypočten) **fakt** – např. objem prodejů

Podkostky (kuboidy)

- Z n-dimenzionální kostky lze odvozovat **podkostky** (kuboidy) – kostky s méně dimenzemi
- Podkostka vznikne **agregací** přes jednu nebo více dimenzí (roll-up)
- Podkostky tvoří **částečně uspořádanou množinu (poset)**:

$$g(A_1 \times \cdots \times A_i \times \cdots \times A_m) \leq g(A_1 \times \cdots \times A_{m-1})$$

Podkostka je „větší", pokud má o jednu dimenzi méně

Kostka jako svaz kuboidů

- Množina všech podkostek jedné kostky tvoří **svaz** (lattice)
- **Vrcholový kuboid** (0-D): jediný agregovaný fakt přes *všechny* dimenze (`all`)
- **Základní kuboid** (*n*-D): fakta pro *všechny* aktivní dimenze

Kostka jako svaz kuboidů

Multidimenzionální kostka jako řídká matice

- Každá dimenze A_i má **skutečnou kardinalitu** k_i (skutečný počet prvků)
- Výsledná kostka je **„vykotlaná" – řídká n-rozměrná matice**
  - Ne všechny průsečíky dimenzí mají definovanou hodnotu faktu
- Příklad: ne pro každou kombinaci (den, produkt, obchod) existuje prodej

3D kostka - příklad 3! otočení

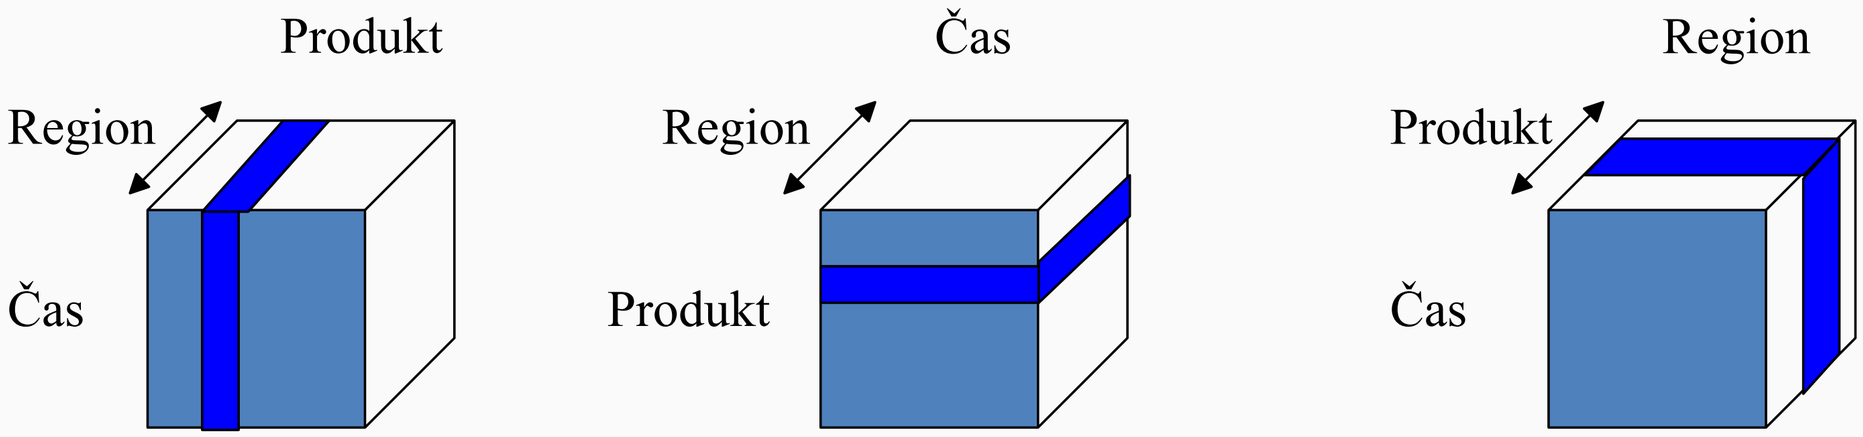

Analýza údajů pro určitý produkt- produkt, region, čas

Analýza pro určité časové období - čas, region, produkt

Analýza údajů podle regionálních kritérií - region, produkt, čas

Je možný i produkt, čas, region - čas, produkt, region a region, čas, produkt.

Agregace

Agregační funkce a výpočet podkostek

Agregační funkce

- **Agregační funkce** shlukují množiny hodnot do jediné hodnoty
- Základní agregační funkce:
  - **Počet** (COUNT)
  - **Součet** (SUM)
  - **Průměr** (AVG)
  - **Maximum** (MAX)
  - **Minimum** (MIN)
- Méně časté:
  - **Medián** – prostřední hodnota uspořádané datové množiny
  - **Modus** – hodnota, která se v množině vyskytuje nejčastěji

Detailní hodnoty

- **Detail** (základní fakt) je existující hodnota na průsečíku hodnot všech dimenzí $(d_1, d_2, \ldots, d_n)$
- Pro stejné hodnoty dimenzí může existovat více faktů (např. více transakcí).

Detailní hodnoty: Příklad

time	item	location	fakt
22.6	rohlík	Praha	6
22.6	rohlík	Brno	12
22.6	rohlík	Brno	4
22.6	párek	Brno	9
22.6	párek	Praha	21
23.6	rohlík	Brno	5
23.6	rohlík	Praha	14
…	…	…	…

První krok agregace detailů

- Pro dané uspořádání dimenzí $\{D_1, D_2, \ldots, D_n\}$ platí pro podkostky $\mathbf{součet}_n$, $\mathbf{počet}_n$, $\mathbf{průměr}_n$ a detailní hodnoty $detail(d_1, d_2, \ldots, d_n)$:

$$\mathbf{součet}_n(d_1, \ldots, d_n) = \sum detail(d_1, d_2, \ldots, d_n)$$

$$\mathbf{počet}_n(d_1, \ldots, d_n) = \sum_{detail(d_1,\ldots,d_n)} 1$$

$$\mathbf{průměr}_n(d_1, \ldots, d_n) = \frac{\mathbf{součet}_n(d_1, \ldots, d_n)}{\mathbf{počet}_n(d_1, \ldots, d_n)}$$

Příklad detailních hodnot

hodnoty dimenzí seřazeny např. vzestupně podle uspořádání

time	item	location	fakt
22.6.	párek	Brno	4
22.6.	párek	Brno	9
22.6.	párek	Praha	21
22.6.	rohlík	Brno	12
22.6.	rohlík	Brno	4
22.6.	rohlík	Brno	3
22.6.	rohlík	Praha	16
22.6.	rohlík	Praha	6
23.6.	rohlík	Brno	5
23.6.	rohlík	Praha	14

celkový součet se nemění

94

více hodnot faktů pro stejné hodnoty dimenzí

První krok pro kostku *součet*

time	item	location	fakt
22.6.	párek	Brno	13
22.6.	párek	Praha	21
22.6.	rohlík	Brno	19
22.6.	rohlík	Praha	22
23.6.	rohlík	Brno	5
23.6.	rohlík	Praha	14
			94

- není více hodnot faktů pro stejné hodnoty dimenzí
- neubylo dimenzí

Podkostky

- Pro $n > m \geq 0$ dimenzí $\{A_1, A_2, \ldots, A_m\}$ platí pro podkostky $\mathbf{součet}_m$, $\mathbf{počet}_m$, $\mathbf{průměr}_m$ a jejich přímé následníky $(m+1)$ v částečném uspořádání $\{A_1, \ldots, A_i, \ldots, A_m\}$:

$$\mathbf{součet}_m(d_1, \ldots, d_m) = \sum_{d_i \in D_i} \mathbf{součet}_{m+1}(d_1, \ldots, d_i, \ldots, d_m)$$

$$\mathbf{počet}_m(d_1, \ldots, d_m) = \sum_{d_i \in D_i} \mathbf{počet}_{m+1}(d_1, \ldots, d_i, \ldots, d_m)$$

Podkostka bez dimenze location

- Agregujeme přes dimenzi *location*:

time	item	fakt
22.6.	párek	34
22.6.	rohlík	41
23.6.	rohlík	19

94

Podkostka bez dimenze item

time	fakt
22.6.	75
23.6.	19
	94

Vrcholový kuboid (0D)

- Agregace přes *všechny* dimenze:

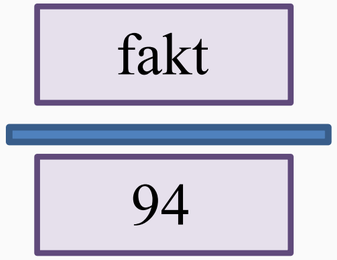

při nulovém počtu dimenzí
jde o celkový agregát

94

- Jediný agregovaný fakt – celkový součet přes vše.

Jiné pořadí dimenzí v prvním kroku

location	time	item	fakt
Brno	22.6.	párek	13
Brno	22.6.	rohlík	19
Brno	23.6.	rohlík	5
Praha	22.6.	párek	21
Praha	22.6.	rohlík	22
Praha	23.6.	rohlík	14

94

Podkostka *součet* bez dimenze item

location	time	fakt
Brno	22.6.	32
Brno	23.6.	5
Praha	22.6.	43
Praha	23.6.	14
		94

Architektury a konceptuální návrh

MOLAP, ROLAP, HOLAP, schémata

Architektury OLAP serveru

- **MOLAP** – Multidimensional OLAP
  - Vlastní multidimenzionální datové struktury (pole, řídké matice)
  - Rychlé indexování předzpracovaných agregovaných dat
  - Výhoda: maximální výkon; Nevýhoda: redundance, velké prostorové nároky
- **ROLAP** – Relational OLAP
  - Data uložena v **relačních tabulkách**, prezentována jako multidimenzionální pohled
  - Žádná redundance; Velká možnost škálování

Architektury OLAP serveru (II)

- **HOLAP** – Hybrid OLAP
  - Detailní data v relačních tabulkách (ROLAP), předagregáty v multidimenzionálních strukturách (MOLAP)
  - Příklad: Microsoft SSAS – mód lze volit per-partition
- **Specializovaný SQL server**
  - Podpora SQL dotazů nad schématy hvězda/sněhová vločka

Příklady OLAP produktů

- **MOLAP**: Oracle Essbase, IBM Planning Analytics (TM1), Jedox
- **ROLAP**: Mondrian/Pentaho (open-source), Apache Kylin, ClickHouse
  - Cloud: Snowflake, Google BigQuery, Amazon Redshift
- **HOLAP**: Microsoft SSAS, SAP BW (SAP Business Warehouse)
- **Specializovaný SQL**: Apache Druid, DuckDB

Konceptuální modelování kostky – schémata

- **Schéma hvězdy** (*star schema*)
  - Jedna tabulka faktů ve středu, připojená k tabulkám dimenzí
- **Schéma sněhové vločky** (*snowflake schema*)
  - Zjemnění hvězdy: hierarchie dimenzí normalizovaná do více tabulek
- **Konstelace faktů** (*fact constellation / galaxy schema*)
  - Více tabulek faktů sdílejících tabulky dimenzí

Fakta a dimenze

- **Tabulka faktů**
  - Největší tabulka v DB (zpravidla jediná)
  - Obsahuje **numerické míry** (tržba, počet, cena)
  - Cizí klíče do tabulek dimenzí
- **Tabulky dimenzí** (číselníky)
  - Logicky nebo hierarchicky uspořádané popisné údaje
  - Menší a mění se méně často
  - Nejčastěji: časová, geografická, produktová dimenze

Schéma hvězdy (star schema)

- Každá relace dimenze sestává z atributů odpovídajících hodnotám dimenze
- **Neposkytuje explicitní podporu pro hierarchii** – lze obejít organizačně
- Relace dimenzí nejsou normalizované → jednoduché, ale pomalejší

Schéma hvězdy (příklad)

Schéma sněhové vločky (snowflake schema)

- Hierarchie dimenzí je **explicitně normalizována** do navázaných tabulek dimenzí
- Výhodná údržba relací dimenzí
- Složitější dotazy, ale lepší konzistence dat dimenzí

Schéma sněhové vločky (příklad)

Celkové schéma datového skladu

OLAP

Operace nad datovou kostkou

On-Line Analytical Processing (OLAP)

- Analytické zpracování údajů v datovém skladu podle uživatelských dotazů
- Uživatel **interaktivně prozkoumává** multidimenzionální data
- Základní operace:
  - **Roll-up** – vyrolování (vzrůst úrovně agregace)
  - **Drill-down** – zavrtání (snížení úrovně agregace)
  - **Pivoting** – přetočení (změna uspořádání dimenzí)
  - **Slicing & Dicing** – seříznutí (výběr projekce)

Příklad komplexní analýzy

- *Propad zisku podniku* → sekvence dotazů:
  1. Celosvětové měsíční prodeje za posledních 5 měsíců
  2. Přehled měsíčních prodejů po regionech → *velký propad v Evropě*
  3. Přehled prodejů v Evropě po zemích → *velký propad ve třech zemích*
  4. Přehled prodejů po zemích a produktech
  5. Přehled přímých a nepřímých nákladů → *nepřímé náklady se zvýšily*
  6. Závěr: **vyšší daň v EU na některé produkty**

Prohlížení datové kostky

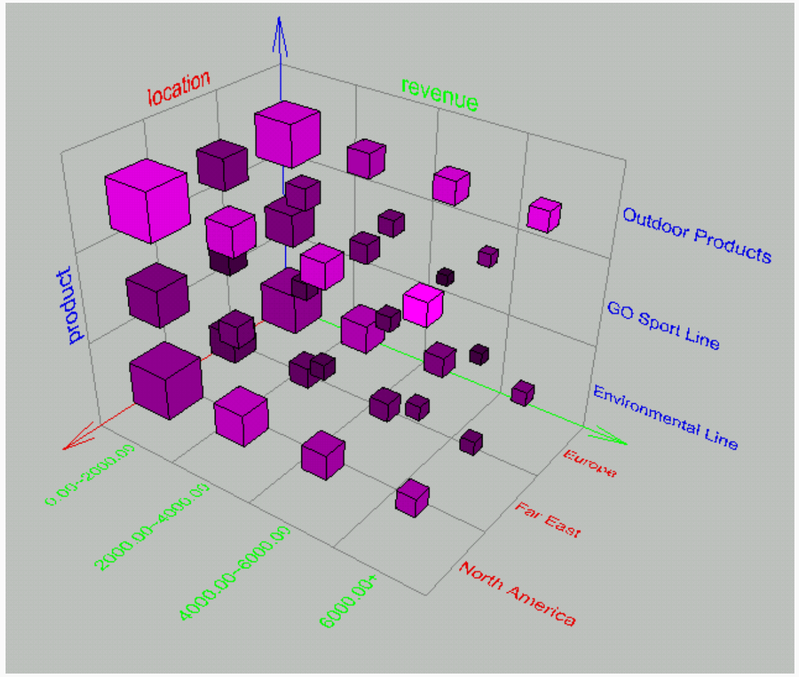

- Vizualizace, operace, interaktivní manipulace

Operace Roll-up

- **Posun o jednu úroveň výše** v uspořádání kuboidů – *vzrůst agregace*
- Vstup: m aktivních dimenzí $\{A_1, A_2, \ldots, A_i, \ldots, A_m\}$
- Výstup: $m - 1$ aktivních dimenzí (A_i bylo deaktivováno)
- Nejčastěji se deaktivuje **nejmenší dimenze** A_m

Příklad: (time × item × location) → roll-up → (time × item)

Operace Drill-down

- **Posun o jednu úroveň níže** v uspořádání kuboidů – *zvýšení detailu*
- Vstup: m aktivních dimenzí $\{A_1, A_2, \ldots, A_m\}$, kde $m \leq n$
- Výstup: $m + 1$ aktivních dimenzí (přidána neaktivní dimenze A_i)
- Nejčastěji se přidá **nejmenší neaktivní dimenze** na konec
- Pro $m = n$ je výsledkem **detail** všech hodnot

Příklad drill-down

LINE	TOTAL SALES
Clothing	$12,836,450
Electronics	$16,068,300
Video	$21,262,190
Kitchen	$17,704,400
Appliances	$19,600,800
Total	$87,472,140

1 High level summary by product line

2 Drill down by year

LINE	1998	1999	2000	TOTAL
Clothing	$3,457,000	$3,590,050	$5,789,400	$12,836,450
Electronics	$5,894,800	$4,078,900	$6,094,600	$16,068,300
Video	$7,198,700	$6,057,890	$8,005,600	$21,262,190
Kitchen	$4,875,400	$5,894,500	$6,934,500	$17,704,400
Appliances	$5,947,300	$6,104,500	$7,549,000	$19,600,800
Total	$27,373,200	$25,725,840	$34,373,100	$87,472,140

3 Rotate columns to rows

YEAR	Clothing	Electronics	Video	Kitchen	Appliances	TOTAL
1998	$3,457,000	$5,894,800	$7,198,700	$4,875,400	$5,947,300	$27,373,200
1999	$3,590,050	$4,078,900	$6,057,890	$5,894,500	$6,104,500	$25,725,840
2000	$5,789,400	$6,094,600	$8,005,600	$6,934,500	$7,549,000	$34,373,100
Total	$12,836,450	$16,068,300	$21,262,190	$17,704,400	$19,600,800	$87,472,140

Figure 15-3 Simple OLAP session.

Operace Pivoting

- **Změna uspořádání dimenzí** (změna relace R) nad stejnou množinou dimenzí
- Vstup: uspořádání $\{D_1, D_2, \ldots, D_n\}$
- Výstup: jiné uspořádání $\{D_{x_1}, D_{x_2}, \ldots, D_{x_n}\}$ – jedna z $n!$ permutací
- Jde o **otočení jedné ze stěn kostky k sobě**

Příklad: (time × item × supplier) → pivoting → (supplier × item × time)

Operace Slicing & Dicing

- **Změna skutečné kardinality** jedné nebo více dimenzí
- Vstup: dimenze $\{D_1, \ldots, D_n\}$ s kardinalitami $k_1, \ldots, k_n$
- Výstup: stejné dimenze, ale změněná kardinalita $k_i \rightarrow l_i$ vybrané dimenze
- Provádí se nastavením **filtru ve tvaru predikátu**
  - Např. „zobraz jen region = Praha" nebo „čas ∈ Q1 2024"
- Výsledek ovlivňují i filtry neaktivních dimenzí

Přehled operací nad kostkou

Operace	Efekt	Příklad
Roll-up	Méně dimenzí, vyšší agregace	měsíc → kvartál → rok
Drill-down	Více dimenzí, větší detail	rok → kvartál → měsíc
Pivoting	Jiné pořadí dimenzí	čas×produkt → produkt×čas
Slice	Fixuje hodnotu jedné dimenze	region = Praha
Dice	Filtr přes více dimenzí	Praha + Q1 + elektro

Přehled operací nad kostkou

Požadavky na OLAP systémy

- Poskytování **agregačních funkcí** podle hierarchií dimenzí
- Možnost **detailního pohledu** (drill-down) na data
- Jednoduché kalkulace (výpočet zisku = prodeje – náklady)
- Sdílení kalkulací pro procentuální vyjádření vůči celku
- **Algebraické rovnice** pro klíčové indikátory výkonnosti (KPI)
- Analýza trendů statistickými metodami

A to je vše!

Dotazy?