




Sémantický web a ontologie

Globální identifikátory, grafový model a dotazování nad propojenými daty


doc. Ing. Radek Burget, Ph.D.

burgetr@fit.vut.cz

Kde jsme



Minule jsme si data brali



Dnes ten druhý pól: co to znamená, když data někdo publikuje i s jejich významem.

Čtyři dluhy z minulé přednášky

- `wdt:P1082` – co to je a proč ten dotaz vůbec fungoval
- `SERVICE wikibase:label` – proč tam musí být
- `data.gov.cz` má SPARQL endpoint – „příští týden pochopíte, co to je“
- `<script type="application/ld+json">` – odkud se ten slovník bere

Na konci dnešní přednášky umíte vysvětlit všechny čtyři.

Jedna firma, nebo tři?

Tři řádky ze tří různých zdrojů

"Vysoké učení technické v Brně"

Brno

scraper e-shopu

"VUT v Brně"

Brno-střed

registr smluv

"Brno University of Technology"

Czechia

publikační databáze

IČO 00216305

wd:Q1122171

Řetězce se neshodují. Identifikátory ano.

- Textový název je **popis**, ne identita
 - mění se, překládá se, píše se s překlepy
 - dvě různé firmy mohou mít stejný název
 - jedna firma může mít pět různých názvů
- **00216305** je **identita**
 - vydaná jednou, nerecyklovaná, nezávislá na jazyku

Spojovat data přes názvy je práce navíc, kterou si **způsobíme sami.**

Dvě odpovědi na tentýž problém

Přístup	Kdy se identita řeší	Čím se platí
Párování řetězců (přednáška 4)	až po sběru dat	podobnostní míry, prahy, chyby
Globální identifikátory (dnes)	už při publikaci dat	někdo se musel předem dohodnout

- Dnešek je ten **druhý řádek**
- Přednáška 4 je ten první – a bude potřeba, protože druhý řádek nikdy nepokryje všechno

Co je globální identifikátor


<http://www.wikidata.org/entity/Q1122171>

- Dereferencovatelný – dá se „zavolat“ přes HTTP a něco se vrátí
- Nezávislý na jazyku a pravopisu
- Jeden pro celý svět, ne pro jednu databázi
- Vydáný jednou a nerecyklovaný

	id = 17	IRI
Platnost	uvnitř jedné databáze	globálně
Export do CSV	význam se ztratí	význam zůstane
Spojení s cizím zdrojem	nutné párování	rovnost řetězců

A najednou to není tabulka


Relační model



Vztah není v datech – je ve **schématu**
a vytáhne se až JOINem.

id = 17 platí jen uvnitř téhle databáze.

Graf (RDF)




Vztah je jedna z trojic – stejně
plnohodnotné datum jako název.

wd:Q14960 platí na celém webu.

Tatáž tři fakta. Vlevo je vztah JOIN, vpravo je vztah datum.

Vztah přestal být JOINem a stal se prvotřídním datem.

Kam to vede



Jedna linka, která prochází celým semestrem – a končí u toho, co se dnes reálně staví.

Dnešek je ta **první krabička zleva**.

Sémantický web

- Představa *webu dat* (*web of data* oproti *web of documents*)
 - Publikování strojově srozumitelných dat
- Základní prvky vize z roku 2001:
 - Reprezentace znalostí – Resource Description Framework (RDF)
 - Sdílená konceptualizace („model světa“) – ontologie
 - Agenti – producenti a konzumenti služeb

Berners-Lee, Tim, Hendler, James, et al. “The Semantic Web : a new form of Web content that is meaningful to computers will unleash a revolution of new possibilities” *Scientific American* 284 (2001) : 34-43

25 let poté

- **Nepřišlo:** autonomní agenti vyjednávací mezi sebou, důkazy, vrstva důvěry
- **Přišlo:** RDF, SPARQL, JSON-LD, schema.org
- **Přežilo pod jiným jménem:** *znalostní graf* (Google 2012, dnes každý větší podnik)

Anotace na webu	2015	2024
Průměrný počet trojic na stránku	10	57

- Z webů, které vůbec něco anotují: JSON-LD $\approx$ 70 %, Microdata $\approx$ 46 %, RDFa $\approx$ 3 %

Web Data Commons: Microdata, RDFa, JSON-LD and Microformat data sets, vydání leden 2025 (extrakce z Common Crawl 10/2024). webdatacommons.org/structureddata

Web dokumentů vs. web dat

World Wide Web

- Základní jednotkou je dokument
- Odkaz vede z dokumentu na dokument
- Význam obsahu je v textu, pro člověka
- Technologie: HTTP, URI, HTML

Sémantický web

- Základní jednotkou je **tvrzení o zdroji**
- Odkaz vede z věci na věc
- Význam je zapsaný explicitně, pro stroj
- Technologie: HTTP, IRI, RDF, ontologie

Stejná infrastruktura, jiná jednotka obsahu.

Z čeho se to skládá

Co se ujalo

IRI / URI

globální identifikátor čehokoli

RDF – datový model

trojice, grafy, pojmenované grafy

Serializace

Turtle · JSON-LD · N-Triples · TriG · RDF/XML

Slovníky a ontologie

RDFS · OWL · SKOS · schema.org · DCAT

Validace

SHACL · ShEx

Dotazování

SPARQL 1.1 · federace přes SERVICE

Aplikace

znalostní grafy, propojená otevřená data

Co se neujalo

Unifying Logic

Proof

Trust

Autonomní agenti

*Horní patra původního
„layer cake“ nikdy
nedostala standard
ani nasazení.*

Stav standardů (2026)

Standard	Stav
RDF 1.1	W3C Recommendation 2014 – tohle běží v praxi
RDF 1.2 Concepts	Candidate Recommendation (duben 2026), <i>triple terms</i>
Turtle, N-Triples, TriG	W3C Recommendation 2014
JSON-LD 1.1	W3C Recommendation 2020
SPARQL 1.1	W3C Recommendation 2013 – tohle se učíme
SPARQL 1.2	zatím jen Working Draft
SHACL 1.0	W3C Recommendation 2017

Standardy se tu hýbou v desetiletích, ne ve verzích za rok.

Datový model – RDF

Reprezentace a výměna faktů v rámci sémantického webu

Cíle a prostředky

- Cíle
 - Reprezentace strukturovaných dat **a jejich významu**
 - Možnost sdílet data i sémantiku napříč aplikacemi
- Běžná reprezentace dat v IS:
 - Relační/objektové/NoSQL databáze – vázané na aplikaci
 - Veřejné API + serializace (JSON, XML) – není definována sémantika

Serializace – příklad

```
<polozka>
  <velikost>3+1</velikost>
  <lokalita>Brno-střed</lokalita>
  <cena mena="czk">8 450 000</cena>
</polozka>
<polozka>
  <velikost>2+1</velikost>
  <lokalita>Kuřim</lokalita>
  <cena mena="czk">5 200 000</cena>
</polozka>
```

Strojově čitelné. Ale co přesně znamená *velikost*?

Problémy

- Význam elementů je specifický pro danou aplikaci
 - Je definován v programovém kódu, který data generuje nebo čte
 - Obdobně jako sloupce v relační databázi
- Jiná aplikace přiřadí týmž značkám jiný význam:

Zdroj A	Zdroj B	Zdroj C
<code><velikost>3+1</velikost></code>	<code><velikost>75</velikost></code>	<code><velikost>75 m2</velikost></code>
dispozice	plocha v m ² , číslo	plocha i s jednotkou

- Data jsou strojově **čitelná** (*machine readable*), ale ne **srozumitelná** (*machine understandable*)
- Tohle je doslova schema matching a normalizace jednotek z přednášky 4

Reprezentace sémantiky

- Odlišení značek v různých aplikacích
 - Např. XML namespaces
 - Řeší kolize značek – syntaktický problém
- Oddělená definice významu značek
 - Např. doprovodný dokument vysvětlující význam a případy použití
 - Čte ho ale člověk, ne program
- Navíc potřebujeme definovat **sémantické vztahy**
 - Byt je věc, která má umístění, velikost a cenu
 - Pokud možno formálně $\Rightarrow$ **ontologie**

Reprezentace faktů: RDF

- RDF: Resource Description Framework
 - Reprezentuje elementární *tvrzení* (fakta)
- Základním prvkem je **RDF trojice: subjekt – predikát – objekt**
- Grafová struktura
 - Tvrzení jsou propojena přes IRI, tvoří orientovaný graf
- Serializace pro uložení a přenos
 - Turtle, JSON-LD, N-Triples, RDF/XML...

Jeden datový model, více zápisů – jako relace vs. CSV/SQL dump.

RDF trojice – tvrzení (statement)




- Subjekt a predikát jsou vždy **IRI**
- Objekt je **IRI** nebo **literál** (jen objekt může být literál)

Kde vzít IRI?

- Vlastní data – vlastní IRI
 - Např. <https://www.fit.vut.cz/student/938272>
 - Obvykle společný *prefix*
- Existující data – veřejné znalostní báze
 - <https://dbpedia.org/resource/Berlin>,
<http://www.wikidata.org/entity/Q42>
- Strukturované slovníky – ontologie
 - IRI pro predikáty a pro typy (třídy) objektů
- Zabudované: [`rdf:type`](#)

RDF graf



- Literál může nést **jazykovou značku** (@cs) nebo **datový typ** (^xsd:date)

Schéma – ontologie




Schéma je psané týmiž trojicemi jako data – jen o patro výš.

- Propojení přes `rdf:type`; schéma je psané opět v RDF
- Data a schéma mohou, ale nemusí být v jednom grafu

Serializace do Turtle

```
@prefix doc: <https://dokumenty.cz/> .
@prefix dct: <http://purl.org/dc/terms/> .
@prefix foaf: <http://xmlns.com/foaf/0.1/> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .

doc:clanek42    dct:title      "Propojená data"@cs ;
                dct:issued    "2026-03-01"^^xsd:date ;
                dct:creator    doc:jan-novak .

doc:jan-novak   a    foaf:Person ;
                foaf:name    "Jan Novák" .
```

- `a` je zkratka za `rdf:type`, `;` opakuje subjekt, `,` opakuje predikát
- Výchozí volba, když má zápis číst člověk

Ostatní serializace

N-Triples – jeden řádek = jedna trojice, bez prefixů. Pro dumpy a streamy.

```
<https://dokumenty.cz/clanek42>  
<http://purl.org/dc/terms/title>  
"Propojená data"@cs .
```

JSON-LD – RDF zapsané jako obyčejný JSON. Nejrozšířenější na webu.

```
{ "@context": "https://schema.org",  
  "@type": "Article",  
  "name": "Propojená data" }
```

- **RDF/XML** – původní zápis z roku 1999, `<rdf:Description rdf:about="...">`. Existuje, psát to nebudete.
- **TriG / N-Quads** – totéž co Turtle / N-Triples plus pojmenované grafy (viz další slajd)

Turtle, N-Triples, TriG i JSON-LD jsou **W3C Recommendation** – žádný z nich není ten „pravý“.

Pojmenované grafy

- Trojice + identifikátor grafu = **kvadrupl** (*quad*)
- Serializace: TriG, N-Quads

```
@prefix wd: <http://www.wikidata.org/entity/> .  
@prefix ex: <https://upa.fit.vut.cz/def#> .  
  
ex:import-wikidata-2026-03 {  
    wd:Q14960 ex:pocetObyvate1 402739 .  
}
```

- **Provenience** – ze kterého zdroje ta trojice je
- **Verzování** – který import ji přinesl a kdy
- **Oddělení dat a schématu** – ontologie zvlášť, instance zvlášť

Bez toho nejde u integrovaných dat říct, komu vlastně nevěřit.

RDF jako databáze

- Repozitář (*triplestore*) – úložiště RDF trojic, dotazování přes SPARQL
- Lokální úložiště:
 - [Apache Jena / Fuseki](#), [RDF4J](#) (dříve Sesame)
 - [Oxigraph](#), [GraphDB](#), [Virtuoso](#)
 - [QLever](#) – zvládne bilion trojic na jednom stroji
 - Amazon Neptune, Stardog
- Globální *znalostní báze*:
 - [DBpedia](#), [Wikidata](#)

Tohle je **grafová databáze**. Druhou rodinu (*property graphs*, Neo4j) potkáte v 9. přednášce.

Veřejné znalostní báze

- **Wikidata** – <http://www.wikidata.org/entity/Q42>
 - SPARQL: query.wikidata.org
 -  9. 5. 2025 **rozdělena na dva grafy**: hlavní a vědecké články (query-scholarly.wikidata.org) – nevešla se na jeden stroj
- **DBpedia** – <https://dbpedia.org/resource/Berlin>
 - SPARQL: dbpedia.org/sparql
 - Strukturovaná data vytěžená z infoboxů Wikipedie
- **Mnoho dalších**, vzájemně propojených přes IRI
 - *Linked Open Data* – lod-cloud.net

Otevřená data

- Serializované RDF jako prostředek pro publikování otevřených (propojených) dat
- **Česko:** data.gov.cz – Národní katalog otevřených dat
 - Má i [SPARQL endpoint](#) – za chvíli se v něm budeme ptát
 - Slovník DCAT-AP-CZ, [otevřené formální normy](#)
- **EU:** data.europa.eu – i zde [SPARQL endpoint](#)
- Možno importovat do lokálního úložiště a dotazovat se spolu s vlastními daty

SPARQL

Dotazování nad grafem – a splacení prvního dluhu

SPARQL je hledání vzoru v grafu

- Dotaz je **graf s proměnnými**; hledá se, čím je lze nahradit
- Proměnná začíná **?**; každý řádek vzoru je jedna trojice

```
SELECT ?mesto ?pocet WHERE {  
  ?mesto wdt:P31 wd:Q5153359 .      # ?mesto je obec v Česku  
  ?mesto wdt:P1082 ?pocet .         # ?mesto má počet obyvatel ?pocet  
}
```

- Databáze najde všechna přiřazení, pro která vzor v grafu existuje
- Žádné tabulky, žádné JOINy – spojení vzniká **opakováním proměnné**

Čtyři formy dotazu

Forma	Výsledek	K čemu v pipeline
SELECT	tabulka (CSV, JSON)	načtu do pandas a pracuji dál
CONSTRUCT	nový graf	transformace: cizí slovník na vlastní
ASK	true / false	kontrola kvality, test v CI
DESCRIBE	graf okolo zdroje	průzkum neznámých dat

- Navíc **SPARQL UPDATE**: **INSERT DATA**, **DELETE WHERE**, **LOAD**
- SPARQL není jen pro čtení – je to plnohodnotný dotazovací i aktualizací jazyk

Ten dotaz z minulé přednášky

```
SELECT ?mestoLabel ?obyvatel WHERE {  
  ?mesto wdt:P31 wd:Q5153359 ;           # je obec v Česku  
        wdt:P1082 ?obyvatel .           # má počet obyvatel  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs". }  
}  
ORDER BY DESC(?obyvatel)
```

- `wd:Q5153359` – **entita** „obec v Česku“
- `wdt:P31` – **vlastnost** „instance čeho“
- `wdt:P1082` – vlastnost „počet obyvatel“
- `?mestoLabel` – proměnná, kterou **nikde nedeklaruji**; doplní ji `SERVICE wikibase:label`

Dluh č. 1 a 2 splacen.

Jak je postavená Wikidata

Prefixy

- **wd:** – entity (**wd:Q14960** = Brno)
 - **wdt:** – vlastnost, *zkratka*
 - **p:** – vlastnost jako **celé tvrzení**
 - **ps:** – hodnota uvnitř tvrzení
 - **pq:** – **kvalifikátor** tvrzení
- Každý dotaz na Wikidata je tedy volba mezi **pohodlím** a **úplností**

Proč to není jedno

wdt: je předpočítaná „truthy“ zkratka: vrátí jen tu hodnotu, která platí teď. Je rychlá a pro devět z deseti dotazů stačí.

p:/ps:/pq: vrátí tvrzení celé – i s časovou platností a zdrojem.

Kvalifikátory: kdo je primátor Brna?

```
SELECT ?xLabel WHERE {  
  wd:Q14960 wdt:P6 ?x .  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs". }  
}
```

Markéta Vaňková

Jeden řádek. **Kde je historie?**

Kvalifikátory: celé tvrzení

```
SELECT ?xLabel ?od ?do WHERE {
  wd:Q14960 p:P6 ?st .           # celé tvrzení o funkci
  ?st ps:P6 ?x .                 # kdo
  OPTIONAL { ?st pq:P580 ?od }   # od kdy
  OPTIONAL { ?st pq:P582 ?do }   # do kdy
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs". }
} ORDER BY DESC(?od)
```

	od	do
Markéta Vaňková	2018-11-20	
Petr Vokřál	2014-11-25	2018-11-20

dalších šest, až do roku 1990

- `wdt:` je zkratka, která **mlčky zahodí časovou platnost**; tvrzení o tvrzení = *reifikace* (v RDF 1.2 na to budou *triple terms*)

SPARQL 1.1: co použijete nejčastěji

Cesty ve vzoru (*property paths*)

```
wd:Q14960 wdt:P131+ ?nadrazenyCelek .
```

+ jedenkrát a více · * nula a více · /
zřetězení · ^ obráceně

Agregace

```
SELECT ?okres (COUNT(*) AS ?pocet)  
WHERE {  
  ?obec wdt:P31 wd:Q5153359 ;  
        wdt:P131 ?okres .  
}  
GROUP BY ?okres HAVING (?pocet > 100)
```

VALUES – vložím vlastní sloupec dat

```
VALUES ?ico { "00216305" "45274649" }
```

Další

OPTIONAL (levé spojení) · FILTER · MINUS ·
UNION · poddotazy · LIMIT / OFFSET

Zkuste `wdt:P131+` napsat v SQL.

Kde to spustit

- Veřejné endpointy: query.wikidata.org · dbpedia.org/sparql · data.gov.cz/sparql · qllever.dev
- Editor [YASGUI](#) – zvýrazňování, našeptávání, export
- Z programu: HTTP GET/POST na endpoint, výsledek jako JSON nebo CSV

```
import requests

r = requests.get("https://query.wikidata.org/sparql",
                 params={"query": open("dotaz.rq").read()},
                 headers={"Accept": "text/csv"})
open("obce.csv", "w").write(r.text)
```

- Vždy začínejte s **LIMIT** – endpointy mají **timeout i rate limit**
- Na velký objem stáhnout dump a nahrát lokálně (Fuseki, Oxigraph, QLever)

Ontologie

Odkud se berou ty slovníky

Ontologie: k čemu to je

„Formální, explicitní specifikace sdílené konceptualizace“

K čemu nám je

- **Dodává význam jednotlivým IRI** – bez ní je `wdt:P1082` jen řetězec
- **Umožňuje integraci dat z různých zdrojů** – společný slovník místo párování názvů

Z čeho se skládá

- **Třídy** (`foaf:Person`), **individua** (`wd:Q14960`), **vlastnosti** (`foaf:knows`)
- *Objektové* vlastnosti míří na zdroj, *datatypové* na literál

Gruber, T. R.: A translation approach to portable ontology specifications. *Knowledge Acquisition* 5(2), 1993. Ve znění, které upřesnil Studer et al. (1998).

RDF Schema a OWL

```
@prefix rdf:    <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .
@prefix rdfs:   <http://www.w3.org/2000/01/rdf-schema#> .
@prefix skola:  <https://upa.fit.vut.cz/skola#> .

skola:Osoba     a rdfs:Class .
skola:Student   a rdfs:Class ;
                rdfs:subClassOf skola:Osoba .

skola:maZapsano a rdf:Property ;
                rdfs:domain skola:Student ;    # subjekt je Student
                rdfs:range  skola:Predmet .    # objekt je Předmět
```

- **RDFS** – třídy, hierarchie, `rdfs:domain` / `rdfs:range`, `rdfs:label`, `rdfs:comment`
- **OWL 2** (W3C Rec 2009, 2. vydání 2012) – výrazně bohatší: ekvivalence, disjunktnost, kardinality, inverzní vlastnosti
 - Profily **EL** / **QL** / **RL** – omezené podjazyky, u kterých je odvozování rychlé
 - Odvozování (*reasoning*) dělají HermiT, ELK, OpenIlet – a je drahé

Propojování entit: owl:sameAs

```
dbr:Brno owl:sameAs wd:Q14960 ,  
    <http://sws.geonames.org/3078610/> ,  
    <http://viaf.org/viaf/144231825> .  
  
schema:taxID a owl:InverseFunctionalProperty .  
# Dvě firmy se stejným IČO jsou tatáž firma.
```

- `owl:sameAs` – **tytéž entity** popsané v různých datasetech
- `owl:differentFrom` – explicitně různé; různá IRI sama o sobě nestačí
- `owl:InverseFunctionalProperty` – **deklarovaný klíč** (IČO!); identita se odvodí sama
-  Formálně to znamená „identické ve všech ohledech“
- V praxi se používá volně – a **přenáší chyby napříč datasey** (*sameAs smell*)

Otevřený svět a SHACL

Předpoklad otevřeného světa

Chybějící tvrzení $\neq$ nepravda. „O téhle firmě nevím cenu“ není „tahle firma nemá cenu“.

V OWL proto **nejde** říct „každý produkt musí mít cenu“. `owl:minCardinality` *odvozuje*, že ta cena někde existuje – nevaliduje, že je v datech.

SHACL (W3C Rec 2017)

Uzavřený svět, **schéma pro RDF**:

```
ex:ProduktShape a sh:NodeShape ;  
  sh:targetClass schema:Product ;  
  sh:property [  
    sh:path schema:price ;  
    sh:minCount 1 ;  
    sh:datatype xsd:decimal ] .
```

Výstupem je *validation report*: co v datech chybí.

Slovníky, které opravdu potkáte

- schema.org – de facto slovník webu
 - Google, Microsoft, Yahoo, Yandex
 - [Product](#), [Offer](#), [Organization](#), [Event](#)
 - Uvidíme za chvíli v JSON-LD
- [DCAT / DCAT-AP-CZ](#) – katalogy datových sad
 - Slovník za data.gov.cz, použitelný v projektu
- [SKOS](#) – taxonomie, číselníky, tezaury
- Rejstřík slovníků: [Linked Open Vocabularies](#) · editor: [Protégé](#) · historické, ale pořád v datech: **FOAF**

Vlastní ontologii tvořte až **naposled**. Napřed hledejte existující.

RDF na Webu

Web of Documents vs. Web of Data

Sémantické anotace

- Propojení HTML a konceptů sémantického webu (IRI)
- Tři zápisy, jeden datový model:
 - **JSON-LD** – blok JSONu v `<script>`, oddělený od obsahu
 - **Microdata** – atributy `itemscope` / `itemprop`
 - **RDFa** – atributy `vocab` / `typeof` / `property`
- Drtivě nejčastější slovník: **schema.org**

Z webů, které něco anotují	podíl
JSON-LD	≈ 70 %
Microdata	≈ 46 %
RDFa	≈ 3 %

Průměrný počet trojic na stránku vzrostl z **10 (2015) na 57 (2024)**.

JSON-LD: nejrozšířenější zápis

```
<script type="application/ld+json">
{ "@context": "https://schema.org",
  "@type": "Product",
  "name": "Kávovar Aurora 2",
  "offers": {
    "@type": "Offer",
    "price": "4990",
    "priceCurrency": "CZK"
  }
}
</script>
```

- Celý trik je `@context`: mapuje krátké klíče na IRI
 - `"name"` $\Rightarrow$ `https://schema.org/name`
- Běžná aplikace to čte jako obyčejný JSON, RDF nástroj jako graf
- JSON-LD 1.1 je **W3C Recommendation** (2020)

Microdata a RDFa

Microdata – v HTML5

```
<div itemscope
  itemtype="https://schema.org/Person">
  <span itemprop="name">Jan Novák</span>
</div>
```

RDFa 1.1 Lite – W3C standard

```
<div vocab="https://schema.org/"
  typeof="Person">
  <span property="name">Jan Novák</span>
</div>
```

- Obojí anotuje **přímo zobrazovaný obsah** – nehrozí rozpor mezi tím, co vidí člověk a co stroj
- Zato se to rozbije při každé změně šablony – proto JSON-LD vyhrál
- Zkrácený zápis (`schema:Person`) se expanduje na plné IRI podle `vocab / prefix`

Zpracování anotací

1. **Parser** – najde anotace v HTML (všechny tři zápisy naráz)
2. **Model** – převede je na množinu trojic
3. **Zpracování** – uloží do triplestoru, nebo serializuje (Turtle, JSON-LD, ...)

```
import requests, extruct

html = requests.get(url).text
data = extruct.extract(html, base_url=url,
                       syntaxes=["json-ld", "microdata", "rdfa"])
```

- Ověřovací nástroje: [Schema Markup Validator](#) · [Google Rich Results Test](#)
- V Pythonu dál [rdflib](#) – trojice, SPARQL nad nimi, serializace

Z HTML na trojice ve třech řádcích – místo tří set řádků scraperu.

Proč to weby vůbec publikují

- Google a spol. z anotací staví **rich results** – hvězdičky, ceny, recepty, události
- Publikující web za to dostane **lepší vzhled ve výsledcích vyhledávání**
- Dokumentace: [Produkty](#), [Filmy](#), [Recepty](#)

Sémantický web na webu nevznikl z ideálů, ale protože se to **vyplatí**.

- Důsledek pro nás: pokrytí je **vychýlené** – e-shopy, recepty, události a firmy ano; cokoli jiného spíš ne
- A publikovaná data jsou **marketingová** – cena bez DPH, dostupnost „skladem“

Dluh č. 4 splacen

- `<script type="application/ld+json">` je **RDF v HTML**
- IRI v něm pocházejí ze **slovníku** – typicky schema.org
- Nástroj (`extract` + `rdflib`) z nich udělá trojice
- Nad trojicemi se dotazujete **stejným SPARQL** jako nad Wikidaty

Anotovaná stránka je malý kousek propojených dat.
Zbývá se podívat na ty velké.

SPARQL v praxi

Co z toho reálně vytáhnu pro svoje data

SPARQL jako nástroj přípravy dat

- **Doplnit** – k mým záznamům přidat, co o nich ví někdo jiný (*enrichment*)
- **Propojit** – najít, že dvě různá IRI označují tutéž věc (*entity linking*)
- **Ověřit** – zkontrolovat vlastní data proti referenčnímu zdroji

Všechny dotazy na následujících slajdech jsou **živé**.
Zkuste je během přednášky.

Doplnit: obohacení o to, co ví Wikidata

Mám nascrapovaný dataset se sloupcem IČO. Co se k němu dá dotáhnout?

```
SELECT ?ico ?firmaLabel ?web ?zalozeno WHERE {  
  VALUES ?ico { "00216305" "45274649" "00025593" }  
  ?firma wdt:P4156 ?ico . # IČO  
  OPTIONAL { ?firma wdt:P856 ?web } # web  
  OPTIONAL { ?firma wdt:P571 ?zalozeno } # datum vzniku  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs,en". }  
}
```

- **VALUES** je doslova „vloř sem svůj sloupec“
- Spojuje se přes **úřední identifikátor**, ne přes název – žádný fuzzy matching

Enrichment ze 4. přednášky hotový jedním dotazem.

A rovnou i první problém

ico	firmaLabel	web	zalozeno
45274649	ČEZ	cez.cz	1992-01-01
00216305	Vysoké učení technické v Brně	vut.cz	1899-01-01
00216305	Vysoké učení technické v Brně	vut.cz	1956-01-01
00025593	Český statistický úřad	csu.gov.cz	1969-01-08

- Tři vstupní řádky, **čtyři výstupní** – VUT má dvě tvrzení o datu vzniku
- Ani jedno není chyba: 1899 je založení české techniky, 1956 dnešní VUT; vícehodnotová vlastnost $\Rightarrow$ **kartézský součin** $\Rightarrow$ duplicity v exportu

Tohle vás v projektu potká.

Řešení: kvalifikátory, agregace, nebo vědomá volba jedné hodnoty.

Propojit: entity linking přes owl:sameAs

Mám IRI z DBpedie. Kde je totéž jinde?

```
SELECT ?stejny WHERE { dbr:Brno owl:sameAs ?stejny }
```

wd:Q14960	← Wikidata
sws.geonames.org/3078610	← GeoNames
viaf.org/viaf/144231825	← knihovny
d-nb.info/gnd/4008456-5	← německá NK
yago-knowledge.org/Brno	← YAGO
de.dbpedia.org/Brünn	← DBpedia (de)

- Record linkage, který za vás **už někdo udělal a publikoval**
- Ve výsledku je ale i [wd:Q850531](#) – což je **okres Brno-město**, ne město

Jeden dotaz, a máte ukázkou propojení **i jeho typické chyby**.

Propojit: klíč do státních registrů

```
SELECT ?obecLabel ?ruian ?obyvatel ?sour WHERE {  
  ?obec wdt:P31 wd:Q5153359 ;      # je obec v Česku  
        wdt:P7606 ?ruian ;          # kód obce v RÚIAN  
        wdt:P625 ?sour .            # souřadnice  
  OPTIONAL { ?obec wdt:P1082 ?obyvatel }  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs". }  
}  
ORDER BY DESC(?obyvatel)
```

obecLabel	ruian	obyvatel	sour
Praha	554782	1397880	Point(14.4214 50.0875)
Brno	582786	402739	Point(16.6083 49.1953)
Ostrava	554821	283187	Point(18.2925 49.8356)

Propojit: prostorová data z OpenStreetMap

```
PREFIX osmkey: <https://www.openstreetmap.org/wiki/Key:>
PREFIX geo:    <http://www.opengis.net/ont/geosparql#>

SELECT ?jmeno ?wikidata ?wkt WHERE {
  ?osm osmkey:amenity "university" ;
      osmkey:name     ?jmeno ;
      osmkey:wikidata ?wikidata ;
      geo:hasGeometry/geo:asWKT ?wkt .
  FILTER(CONTAINS(?jmeno, "Brn"))
}
```

- Endpoint qllever.dev – celý OpenStreetMap jako RDF
- OSM nese tag `wikidata=*` – **entity linking dělaný dobrovolníky**
- Geometrie přijde jako **WKT**, tedy ve formátu, který načte PostGIS

Overit: federace přes dva endpointy

Wikidata se **9. 5. 2025 rozdělila na dva grafy** – vědecké články byly přes polovinu trojic a přestalo se to vejít na jeden stroj.

```
PREFIX wdsubgraph: <https://query.wikidata.org/subgraph/>

SELECT ?jmeno ?nar WHERE {
  VALUES ?clanek { wd:Q29164671 }
  ?clanek wdt:P50 ?autor .                # článek → autoři
  SERVICE wdsubgraph:wikidata_main {     # skok do druhého grafu
    ?autor wdt:P569 ?nar ; rdfs:label ?jmeno .
    FILTER(LANG(?jmeno) = "cs")
  }
}
```

```
Tim Berners-Lee 1955-06-08 | James Hendler 1957-04-02
```

Česká otevřená data: ověřte si mě

Na úvodní přednášce jsem tvrdil, že se u nás publikuje nejvíc v XML. Odkud to vím?

```
PREFIX dcat:<http://www.w3.org/ns/dcat#>
PREFIX dct:<http://purl.org/dc/terms/>

SELECT ?format
      (COUNT(DISTINCT ?d) AS ?n)
WHERE {
  ?d      a dcat:Dataset ;
         dcat:distribution ?dist .
  ?dist  dct:format ?format .
}
GROUP BY ?format
ORDER BY DESC(?n)
```

formát	sad	formát	sad
ZIP	11 890	JSON-LD	1 130
XML	11 782	GeoJSON	796
CSV	5 126	KML	714
JSON	1 823	HTML	581

Endpoint data.gov.cz/sparql – **dluh č. 3 splacen.**

Katalog jako graf: vstup do projektu

Chci URL ke stažení všech CSV o kvalitě ovzduší – bez klikání v katalogu.

```
PREFIX dcat:<http://www.w3.org/ns/dcat#>
PREFIX dct:  <http://purl.org/dc/terms/>

SELECT DISTINCT ?nazev ?url WHERE {
  ?ds    a dcat:Dataset ; dct:title ?nazev ; dcat:distribution ?dist .
  ?dist dcat:downloadURL ?url ; dct:format ?f .
  FILTER(STRENDS(STR(?f), "file-type/CSV"))
  FILTER(CONTAINS(LCASE(?nazev), "ovzduší"))
}
```

Kvalita ovzduší – aktuální hodinové údaje	opendata.chmi.cz/air_quality/
Kvalita ovzduší – data z mobilních stanic	data.brno.cz/api/download/...
Emise znečišťujících látek (REZZO 1-4)	data.csu.gov.cz/opendata/...

- Výstupem dotazu je **seznam URL** – ten rovnou pustíte do [curl](#) z minulé přednášky
- Metadata katalogu jsou graf; dotazují se tedy **na data o datech**

Transformace pomocí CONSTRUCT

```
PREFIX ex: <https://upa.fit.vut.cz/def#>

CONSTRUCT {
  ?obec ex:ruianKod ?ruian ; ex:nazev ?jmeno ;
        ex:pocetObyvatel ?obyvatel .
} WHERE {
  ?obec wdt:P31 wd:Q5153359 ; wdt:P7606 ?ruian ;
        wdt:P1082 ?obyvatel ; rdfs:label ?jmeno .
  FILTER(LANG(?jmeno) = "cs" && ?obyvatel > 20000)
}
```

- Výsledkem **není tabulka, ale graf** – přemapovaný na můj vlastní slovník
- Tenhle výstup nahraju do svého úložiště a dál se ptám jen na něj
- Dotaz jako **ETL transformace**, zapsaná deklarativně

Kde to naráží


- **Timeouty a rate limity** – veřejný endpoint vám velký dotaz nedopočítá
- **Nerovnoměrné pokrytí** – Wikidata vědí o Brně všechno a o vaší firmě nic
- **Kvalita** – historické hodnoty, chybějící kvalifikátory, volně použité [owl:sameAs](#)
- **Dostupnost** – endpoint je cizí server; dnes běží, zítra vrátí 502 (viz RÚIAN)

Nad určitou velikost se dump **stáhne a nahraje lokálně** (Fuseki, Oxigraph, QLever) – a tím jsme zpátky u ukládání dat.

Čtyři dluhy splaceny

- ✓ `wdt:P1082` – vlastnost „počet obyvatel“ ve slovníku Wikidat; `wdt:` je truthy zkratka
- ✓ `SERVICE wikibase:label` – doplní `?xLabel` k `?x`, protože popisky jsou zvlášť
- ✓ `data.gov.cz/sparql` – katalog otevřených dat jako graf ve slovníku DCAT-AP-CZ
- ✓ `<script type="application/ld+json">` – RDF v HTML, slovník obvykle `schema.org`

Příště: porozumění datům



Data už máme – dvěma různými cestami. Příště: **co v nich vlastně je.**

A to je vše!

Veškeré materiály jsou / budou v E-learning VUT (Moodle)

Dotazy?