




Sémantický web a ontologie

Propojená data a popis jejich sémantiky


doc. Ing. Radek Burget, Ph.D.

burgetr@fit.vutbr.cz

Kde jsme



Minule jsme si data brali



Dnes ten druhý pól: co to znamená, když data někdo publikuje i s jejich významem.

Sémantický web

- Představa *webu dat* (*web of data* oproti *web of documents*)
 - Publikování strojově srozumitelných dat
- Základní prvky:
 - Reprezentace znalostí – Resource description framework (RDF)
 - Sdílená konceptualizace („model světa“) – ontologie
 - Agenti – producenti a konzumenti služeb

Berners-Lee, Tim, Hendler, James, et al. “The Semantic Web : a new form of Web content that is meaningful to computers will unleash a revolution of new possibilities” *Scientific American* 284 (2001) : 34-43

25 let poté

- **Nepřišlo:** autonomní agenti vyjednávací mezi sebou, důkazy, vrstva důvěry
 - **Místo toho:** agenti založení na LLM
- **Přišlo:** RDF, SPARQL, JSON-LD, ontologie (schema.org, apod.)
- **Přežilo pod jiným jménem:** *znalostní graf* (Google 2012, dnes každý větší podnik)
- **Reálně rostoucí využití:**
 - E-commerce, vyhledávače
 - Otevřené datové sady (linked open data)

Web dokumentů vs. web dat

World Wide Web

- Základní jednotkou je dokument
- Odkaz vede z dokumentu na dokument
- Význam obsahu je implicitní, v textu, pro člověka
- Technologie: HTTP, URI, HTML

Sémantický web

- Základní jednotkou je **tvrzení o zdroji**
- Odkaz vede z věci na věc
- Význam je sdílený, zapsaný explicitně, pro stroj
- Technologie: HTTP, IRI, RDF, ontologie

Základní technologie

Co se ujalo

IRI / URI

globální identifikátor čehokoli

RDF – datový model

trojice, grafy, pojmenované grafy

Serializace

Turtle · JSON-LD · N-Triples · TriG · RDF/XML

Slovníky a ontologie

RDFS · OWL · SKOS · schema.org · DCAT

Validace

SHACL · ShEx

Dotazování

SPARQL 1.1 · federace přes SERVICE

Aplikace

znalostní grafy, propojená otevřená data

Co se neujalo

Unifying Logic

Proof

Trust

Autonomní agenti

*Horní patra původního
„layer cake“ nikdy
nedostala standard
ani nasazení.*

Datový model – RDF

Reprezentace a výměna faktů v rámci sémantického webu

Cíle a prostředky

- Cíle
 - Reprezentace strukturovaných dat a jejich významu (sémantiky)
 - Možnost sdílet data a jejich sémantiku napříč aplikacemi
- Běžná reprezentace dat v IS:
 - Relační/objektové/NoSQL databáze – vázané na aplikaci
 - Veřejná API + serializace (JSON, XML) – není definována sémantika

Serializace – příklad

```
<nabidka>
  <polozka>
    <velikost>3+1</velikost>
    <lokalita>Brno-střed</lokalita>
    <cena mena="czk">2 200 000</cena>
  </polozka>
  <polozka>
    <velikost>2+1</velikost>
    <lokalita>Kuřim</lokalita>
    <cena mena="czk">450 000</cena>
  </polozka>
</nabidka>
```

Problémy

- Význam elementů je specifický pro danou aplikaci
 - Je definován v programovém kódu, který data generuje nebo čte
 - Obdobně jako sloupce v relační databázi
- Jiná aplikace přiřadí týmž značkám jiný význam:

Zdroj A	Zdroj B	Zdroj C
<code><velikost>3+1</velikost></code>	<code><velikost>75</velikost></code>	<code><velikost>75 m2</velikost></code>
dispozice	plocha v m ² , číslo	plocha i s jednotkou

- Data jsou strojově **čitelná** (*machine readable*), ale ne **srozumitelná** (*machine understandable*)

Identifikace

- Jak identifikovat entity, které popisujeme?
 - Např. VUT, Brno, ...
- Lokální identifikátory (např. generované)
 - Specifické pro konkrétní databázi, při exportu ztrácí smysl
- Unikátní hodnoty z nějakého číselníku (jsou-li k dispozici)
 - Specifické pro různé entity: IČ / DIČ / VAT pro firmu, r.č. pro člověka (chceme ho sdílet?), často nic z toho není k dispozici

Základní myšlenka sémantického webu

- Každé entitě (konkrétní osoba, firma, kniha, film, ...) přiřadíme **IRI**
 - Jednoznačná identifikace nezávislá na původu datasetu a typu entity (**IRI** je zobecnění **URL**)
 - Např. Brno: <http://www.wikidata.org/entity/Q14960>
- Kdokoliv může publikovat **tvrzení** o libovolné entitě
 - Např. Brno má 377508 obyvatel (k 1. 1. 2014)
- Tvrzení může odkazovat na jiné entity
 - Např. Brno je v České republice.

Reprezentace faktů: RDF

- RDF: Resource Description Framework
 - Reprezentuje elementární *tvrzení* (fakta)
- Základním prvkem je **RDF trojice: subjekt – predikát – objekt**
- Grafová struktura
 - Tvrzení jsou propojena přes IRI, tvoří orientovaný graf
- Serializace pro uložení a přenos
 - Turtle, JSON-LD, N-Triples, RDF/XML...

RDF trojice – tvrzení (statement)




- Subjekt a predikát jsou vždy **IRI**
- Objekt je **IRI** nebo **literál** (jen objekt může být literál)
- Zkrácený zápis IRI:
 - `dcterms:` je *prefix*, který se expanduje
 - `dcterms:creator` => `http://purl.org/dc/terms/creator`

Kde vzít IRI?


- Vlastní data – vlastní IRI
 - Např. <https://www.fit.vut.cz/student/938272>
 - Obvykle společný *prefix*
- Existující data – veřejné znalostní báze
 - <https://dbpedia.org/resource/Berlin>,
<http://www.wikidata.org/entity/Q42>
- Ontologie – strukturované slovníky
 - IRI pro **predikáty** a pro **typy** (třídy) objektů
- Zabudované: [rdf:type](#)

RDF graf



- Literál může nést **jazykovou značku** (@cs) nebo **datový typ** (^^xsd:date)

Schéma – ontologie



- Propojení přes `rdf:type`; schéma je definované opět RDF trojicemi
 - Jen používáme jiný slovník – RDFS, OWL
- Data a schéma mohou, ale nemusí být uložena společně

Serializace do Turtle

```
@prefix doc: <https://dokumenty.cz/> .
@prefix dct: <http://purl.org/dc/terms/> .
@prefix foaf: <http://xmlns.com/foaf/0.1/> .
@prefix xsd: <http://www.w3.org/2001/XMLSchema#> .

doc:clanek42    dct:title      "Propojená data"@cs ;
                dct:issued    "2026-03-01"^^xsd:date ;
                dct:creator    doc:jan-novak .

doc:jan-novak   a    foaf:Person ;
                foaf:name   "Jan Novák" .
```

- `a` je zkratka za `rdf:type`, `;` opakuje subjekt, `,` opakuje predikát
- Výchozí volba, když má zápis číst člověk

Ostatní serializace

N-Triples – jeden řádek = jedna trojice, bez prefixů. Pro dumpy a streamy.

```
<https://dokumenty.cz/clanek42>  
<http://purl.org/dc/terms/title>  
"Propojená data"@cs .
```

JSON-LD – RDF zapsané jako obyčejný JSON. Nejrozšířenější na webu.

```
{ "@context": "https://schema.org",  
  "@type": "Article",  
  "name": "Propojená data" }
```

- **RDF/XML** – původní zápis z roku 1999, `<rdf:Description rdf:about="...">`. Existuje, psát to nebudete.
- **TriG / N-Quads** – totéž co Turtle / N-Triples plus pojmenované grafy (viz další slajd)

Turtle, N-Triples, TriG i JSON-LD jsou **W3C Recommendation** .

Pojmenované grafy

- Trojice + identifikátor grafu = **čtveřice** (*quad*)
- Serializace: TriG, N-Quads

```
@prefix wd: <http://www.wikidata.org/entity/> .  
@prefix ex: <https://upa.fit.vut.cz/def#> .  
  
ex:import-wikidata-2026-03 {  
    wd:Q14960 ex:pocetObyvate1 402739 .  
}
```

- **Provenience** – ze kterého zdroje ta trojice je
- **Verzování** – který import ji přinesl a kdy
- **Oddělení dat a schématu** – ontologie zvlášť, instance zvlášť

Při integraci zdrojů: Umožňuje určit, ze kterého zdroje jaké tvrzení pochází – např. v případě konfliktu, aktualizace, apod.

RDF jako databáze

- Repozitář (*triplestore*) – úložiště RDF trojic, dotazování přes SPARQL
- Lokální úložiště:
 - [Apache Jena / Fuseki](#), [RDF4J](#) (dříve Sesame)
 - [Oxigraph](#), [GraphDB](#), [Virtuoso](#)
 - [QLever](#) – zvládne bilion trojic na jednom stroji
 - Amazon Neptune, Stardog
- Globální *znalostní báze*:
 - [DBpedia](#), [Wikidata](#)

Tohle je **grafová databáze**. Druhou rodinu (*property graphs*, Neo4j) potkáte v „ukádacích“ přednáškách.

Veřejné znalostní báze

- **Wikidata** – <http://www.wikidata.org/entity/Q42>
 - SPARQL: query.wikidata.org
- **DBpedia** – <https://dbpedia.org/resource/Berlin>
 - SPARQL: dbpedia.org/sparql
 - Strukturovaná data vytěžená z infoboxů Wikipedie
- **Mnoho dalších**, vzájemně propojených přes IRI
 - *Linked Open Data* – lod-cloud.net

Otevřená data

- Serializované RDF jako prostředek pro publikování otevřených (propojených) dat
- **Česko:** data.gov.cz – Národní katalog otevřených dat
 - Má i [SPARQL endpoint](#) – za chvíli se v něm budeme ptát
 - Slovník DCAT-AP-CZ, [otevřené formální normy](#)
- **EU:** data.europa.eu – i zde [SPARQL endpoint](#)
- Serializovaná data (dump), např. v [TriG](#) nebo [Turtle](#)
 - Možno importovat do lokálního úložiště a dotazovat se spolu s vlastními daty
 - Např. [Číselník pro sporty](#), [Přehled OSVČ](#)

SPARQL

Dotazování nad grafem

SPARQL: hledání vzoru v grafu

- Dotaz je **graf s proměnnými**; hledá se, čím je lze nahradit
- Proměnná začíná **?**; každý řádek vzoru je jedna trojice

```
SELECT ?mesto ?pocet WHERE {  
  ?mesto wdt:P31 wd:Q5153359 .      # ?mesto je obec v Česku  
  ?mesto wdt:P1082 ?pocet .         # ?mesto má počet obyvatel ?pocet  
}
```

- Databáze najde všechna přiřazení, pro která vzor v grafu existuje
- Žádné tabulky, žádné JOINy – spojení vzniká **opakováním proměnné**
- query.wikidata.org

Kde to spustit

- Veřejné endpointy: query.wikidata.org · dbpedia.org/sparql · data.gov.cz/sparql · qllever.dev
- Editor [YASGUI](#) – zvýrazňování, našeptávání, export
- Z programu: HTTP GET/POST na endpoint, výsledek jako JSON nebo CSV

```
import requests

r = requests.get("https://query.wikidata.org/sparql",
                 params={"query": open("dotaz.rq").read()},
                 headers={"Accept": "text/csv"})
open("obce.csv", "w").write(r.text)
```

- Vždy začínejte s **LIMIT** – endpointy mají **timeout i rate limit**
- Na velký objem stáhnout dump a nahrát lokálně (Fuseki, Oxigraph, QLever)

Čtyři formy dotazu

Forma	Výsledek	K čemu v pipeline
SELECT	tabulka (CSV, JSON)	načtu do pandas a pracuji dál
CONSTRUCT	nový graf	transformace: cizí slovník na vlastní
ASK	true / false	kontrola kvality, test v CI
DESCRIBE	graf okolo zdroje	průzkum neznámých dat

- **SPARQL UPDATE:** INSERT DATA, DELETE WHERE, LOAD

Verze s názvem obce

- Filtr na počet obyvatel

```
SELECT ?mesto ?nazev ?pocet WHERE {  
  ?mesto wdt:P31 wd:Q5153359 .      # ?mesto je obec v Česku  
  ?mesto wdt:P1448 ?nazev .         # ?nazev je oficiální název  
  ?mesto wdt:P1082 ?pocet .         # ?mesto má počet obyvatel ?pocet  
  FILTER (?pocet > 100000)  
}
```

- query.wikidata.org

Dotaz na DBPedia

```
PREFIX dbprop: <http://dbpedia.org/property/>
PREFIX dbo: <http://dbpedia.org/ontology/>
SELECT DISTINCT ?country ?name ?curLabel ?cur
WHERE
{
  ?country rdf:type dbo:Country;
    dbprop:commonName ?name ;
    dbo:currency ?cur .
  ?cur rdfs:label ?curLabel .
  OPTIONAL {?country dbprop:yearEnd ?yearEnd}
  FILTER (!bound(?yearEnd) && lang(?curLabel) = "en")
}
```

- <https://dbpedia.org/sparql>
- <https://qlever.dev/dbpedia/>

Dotaz data.gov.cz

- Rejstřík orgánů veřejné moci: ID datových schránek všech krajských úřadů

```
PREFIX ovm: <https://slovník.gov.cz/legislativní/sbírka/111/2009/pojem/>
PREFIX rpp: <https://slovník.gov.cz/agendový/104/pojem/>

SELECT ?nazev ?ico ?schranka WHERE {
  ?z      rpp:zařazuje-do-kategorie/ovm:má-název-kategorie "Krajské úřady"@cs
          rpp:má-zařazený-subjekt      ?urad .
  ?urad   ovm:má-název-orgánu-veřejné-moci ?nazev ;
          ovm:má-identifikační-číslo-osoby-orgánu-veřejné-moci ?ico ;
          ovm:má-datovou-schránku-orgánu-veřejné-moci/ovm:má-identifikátor-da
}
ORDER BY ?nazev
```

- data.gov.cz/sparql – 13 krajů, IRI včetně diakritiky

Výsledek

nazev	ico	schranka
Jihomoravský kraj	70888337	x2pbqzq
Jihočeský kraj	70890650	kdib3rr
Karlovarský kraj	70891168	siqbx2
Kraj Vysočina	70890749	ksab3eu
Královéhradecký kraj	70889546	gcgbp3q
...	...	...

- **?z** je **pomocný uzel** – zařazení do kategorie nese i datum, proto není vztah přímý
- **/** je **property path**: zkratka za průchod přes mezilehlý uzel

Ontologie

Odkud se berou ty slovníky

Ontologie: k čemu to je

„Formální, explicitní specifikace sdílené konceptualizace“

K čemu nám je

- **Dodává význam jednotlivým IRI** – bez ní je `wdt:P1082` jen řetězec
- **Umožňuje integraci dat z různých zdrojů** – společný slovník místo párování názvů

Z čeho se skládá

- **Třídy** (`foaf:Person`), **individua** (`wd:Q14960`), **vlastnosti** (`foaf:knows`)
- *Objektové* vlastnosti míří na zdroj, *datatypové* na literál

Gruber, T. R.: A translation approach to portable ontology specifications. *Knowledge Acquisition* 5(2), 1993. Ve znění, které upřesnil Studer et al. (1998).

RDF Schema a OWL

```
@prefix rdf:    <http://www.w3.org/1999/02/22-rdf-syntax-ns#> .
@prefix rdfs:   <http://www.w3.org/2000/01/rdf-schema#> .
@prefix skola:  <https://upa.fit.vut.cz/skola#> .

skola:Osoba    a rdfs:Class .
skola:Student  a rdfs:Class ;
               rdfs:subClassOf skola:Osoba .

skola:maZapsano a rdf:Property ;
               rdfs:domain skola:Student ;    # subjekt je Student
               rdfs:range  skola:Predmet .    # objekt je Předmět
```

- **RDFS** – třídy, hierarchie, `rdfs:domain` / `rdfs:range`, `rdfs:label`, `rdfs:comment`
- **OWL 2** (W3C Rec 2009, 2. vydání 2012) – výrazně bohatší: ekvivalence, disjunktnost, kardinality, inverzní vlastnosti

Propojování entit: owl:sameAs

```
dbr:Brno owl:sameAs wd:Q14960 ,  
    <http://sws.geonames.org/3078610/> ,  
    <http://viaf.org/viaf/144231825> .
```

- `owl:sameAs` – **tytéž entity** popsané v různých datasetech
- `owl:differentFrom` – explicitně různé; různá IRI sama o sobě nestačí

Otevřený svět a SHACL

Předpoklad otevřeného světa

Chybějící tvrzení $\neq$ nepravda. „O tomto produktu nevím cenu“ není „tento produkt nemá cenu“.

V OWL proto **nejde** říct „každý produkt musí mít cenu“. `owl:minCardinality` *odvozuje*, že ta cena někde existuje – nevaliduje, že je v datech.

SHACL (W3C Rec 2017)

Uzavřený svět, **schéma pro RDF**:

```
ex:ProduktShape a sh:NodeShape ;  
  sh:targetClass schema:Product ;  
  sh:property [  
    sh:path schema:price ;  
    sh:minCount 1 ;  
    sh:datatype xsd:decimal ] .
```

Výstupem je *validation report*: co v datech chybí.

Reálně používané slovníky (ontologie)

- schema.org – de facto slovník webu
 - Google, Microsoft, Yahoo, Yandex
 - [Product](#), [Offer](#), [Organization](#), [Event](#)
 - Uvidíme za chvíli v JSON-LD
 - [DCAT / DCAT-AP-CZ](#) – katalogy datových sad
 - Slovník za data.gov.cz, použitelný v projektu
 - [SKOS](#) – taxonomie, číselníky, tezaury
 - Rejstřík slovníků: [Linked Open Vocabularies](#) · editor: [Protégé](#) · historické, ale pořád v datech: **FOAF**
- Vlastní ontologii tvořte až **když není vyhnutí**. Napřed hledejte existující.

RDF na Webu

Web of Documents vs. Web of Data

Sémantické anotace

- Propojení HTML a konceptů sémantického webu (IRI)
- Tři zápisy, jeden datový model:
 - **JSON-LD** – blok JSONu v `<script>`, oddělený od obsahu
 - **Microdata** – atributy `itemscope` / `itemprop`
 - **RDFa** – atributy `vocab` / `typeof` / `property`
- Drtivě nejčastější slovník: **schema.org**

Z webů, které něco anotují	podíl
JSON-LD	≈ 70 %
Microdata	≈ 46 %
RDFa	≈ 3 %

Průměrný počet trojic na stránku vzrostl z **10 (2015) na 57 (2024)**.

JSON-LD: nejrozšířenější zápis

```
<script type="application/ld+json">
{ "@context": "https://schema.org",
  "@type": "Product",
  "name": "Kávovar Aurora 2",
  "offers": {
    "@type": "Offer",
    "price": "4990",
    "priceCurrency": "CZK"
  }
}
</script>
```

- `@context`: mapuje krátké klíče na IRI
 - `"name"` $\Rightarrow$ `https://schema.org/name`
- Běžná aplikace vidí obyčejný JSON, RDF nástroj jako graf
- JSON-LD 1.1 je **W3C Recommendation** (2020)

Microdata a RDFa

Microdata – v HTML5

```
<div itemscope  
  itemtype="https://schema.org/Person">  
  <span itemprop="name">Jan Novák</span>  
</div>
```

RDFa 1.1 Lite – W3C standard

```
<div vocab="https://schema.org/"  
  typeof="Person">  
  <span property="name">Jan Novák</span>  
</div>
```

- Obojí anotuje **přímo zobrazovaný obsah** – nehrozí rozpor mezi tím, co vidí člověk a co stroj
- Zato se to rozbije při každé změně šablony – proto JSON-LD vyhrál
- Zkrácený zápis (`schema:Person`) se expanduje na plné IRI podle `vocab / prefix`

Zpracování anotací

1. **Parser** – najde anotace v HTML (všechny tři zápisy naráz)
2. **Model** – převede je na množinu trojic
3. **Zpracování** – uloží do triplestoru, nebo serializuje (Turtle, JSON-LD, ...)

```
import requests, extract

html = requests.get(url).text
data = extract.extract(html, base_url=url,
                       syntaxes=["json-ld", "microdata", "rdfa"])
```

- Ověřovací nástroje: [Schema Markup Validator](#) · [Google Rich Results Test](#)
- V Pythonu dál [rdflib](#) – trojice, SPARQL nad nimi, serializace

Z HTML na trojice ve třech řádcích – místo tří set řádků scraperu.

Proč to weby vůbec publikují

- Google a spol. z anotací staví **rich results** – hvězdičky, ceny, recepty, události
- Publikující web za to dostane **lepší vzhled ve výsledcích vyhledávání**
- Dokumentace: [Produkty](#), [Filmy](#), [Recepty](#)
- Pokrytí je **nevyvážené** – e-shopy, recepty, události a firmy ano; cokoli jiného spíš ne
- A publikovaná data jsou **marketingová** – cena bez DPH, dostupnost „skladem“

Sémantický web a web jsou **různé věci**.

RDF data mohou existovat bez WWW stránek.

SPARQL v praxi

Co z toho reálně vytáhnu pro svoje data

SPARQL jako nástroj přípravy dat

- **Doplnit** – k mým záznamům přidat, co o nich ví někdo jiný (*enrichment*)
- **Propojit** – najít, že dvě různá IRI označují tutéž věc (*entity linking*)
- **Ověřit** – zkontrolovat vlastní data proti referenčnímu zdroji

Všechny dotazy na následujících slajdech jsou **živé**.
Zkuste je během přednášky.

Doplnit: obohacení o to, co ví Wikidata

Mám nascrapovaný dataset se sloupcem IČO. Co se k němu dá dotáhnout?

```
SELECT ?ico ?firmaLabel ?web ?zalozeno WHERE {  
  VALUES ?ico { "00216305" "45274649" "00025593" }  
  ?firma wdt:P4156 ?ico . # IČO  
  OPTIONAL { ?firma wdt:P856 ?web } # web  
  OPTIONAL { ?firma wdt:P571 ?zalozeno } # datum vzniku  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs,en". }  
}
```

- **VALUES** definuje uvažované hodnoty **?ico**
- Kde se ptát?
 - <https://query.wikidata.org/>
 - <https://qllever.dev/wikidata>

A rovnou i první problém

ico	firmaLabel	web	zalozeno
45274649	ČEZ	cez.cz	1992-01-01
00216305	Vysoké učení technické v Brně	vut.cz	1899-01-01
00216305	Vysoké učení technické v Brně	vut.cz	1956-01-01
00025593	Český statistický úřad	csu.gov.cz	1969-01-08

- Tři vstupní řádky, **čtyři výstupní** – VUT má dvě tvrzení o datu vzniku
- Ani jedno není chyba: 1899 je založení české techniky, 1956 dnešní VUT; vícehodnotová vlastnost $\Rightarrow$ **kartézský součin** $\Rightarrow$ duplicity v exportu

Řešení: kvalifikátory, agregace, nebo vědomá volba jedné hodnoty.

Oficiální název přes P1448

```
SELECT ?ico ?nazev ?web ?zalozeno WHERE {  
  VALUES ?ico { "00216305" "45274649" "00025593" }  
  ?firma wdt:P4156 ?ico . # IČO  
  ?firma wdt:P1448 ?nazev . # Nazev  
  OPTIONAL { ?firma wdt:P856 ?web } # web  
  OPTIONAL { ?firma wdt:P571 ?zalozeno } # datum vzniku  
}
```

- Ještě větší exploze stavů

Propojit: entity linking přes owl:sameAs

Mám IRI z DBpedie. Kde je totéž jinde?

```
SELECT ?stejny WHERE { dbr:Brno owl:sameAs ?stejny }
```

wd:Q14960	← Wikidata
sws.geonames.org/3078610	← GeoNames
viaf.org/viaf/144231825	← knihovny
d-nb.info/gnd/4008456-5	← německá NK
yago-knowledge.org/Brno	← YAGO
de.dbpedia.org/Brünn	← DBpedia (de)

- <https://dbpedia.org/sparql>

- Record linkage, který za vás **už někdo udělal a publikoval**
- Ve výsledku je ale i [wd:Q850531](#) – což je **okres Brno-město**, ne město

Propojit: klíč do státních registrů

```
SELECT ?obecLabel ?ruian ?obyvateL ?sour WHERE {  
  ?obec wdt:P31 wd:Q5153359 ;      # je obec v Česku  
        wdt:P7606 ?ruian ;          # kód obce v RÚIAN  
        wdt:P625 ?sour .            # souřadnice  
  OPTIONAL { ?obec wdt:P1082 ?obyvateL }  
  FILTER (?obyvateL > 100000)  
  SERVICE wikibase:label { bd:serviceParam wikibase:language "cs". }  
}  
ORDER BY DESC(?obyvateL)
```

obecLabel	ruian	obyvateL	sour
Praha	554782	1397880	Point(14.4214 50.0875)
Brno	582786	402739	Point(16.6083 49.1953)
Ostrava	554821	283187	Point(18.2925 49.8356)

Propojit: prostorová data z OpenStreetMap

```
PREFIX osmkey: <https://www.openstreetmap.org/wiki/Key:>
PREFIX geo:    <http://www.opengis.net/ont/geosparql#>

SELECT ?jmeno ?wikidata ?wkt WHERE {
  ?osm osmkey:amenity "university" ;
      osmkey:name     ?jmeno ;
      osmkey:wikidata ?wikidata ;
      geo:hasGeometry/geo:asWKT ?wkt .
  FILTER(CONTAINS(?jmeno, "Brn"))
}
```

- Endpoint qllever.dev – celý OpenStreetMap jako RDF
- Geometrie přijde ve formátu **WKT**, který načte PostGIS
- VUT nemá jednu budovu, zkusme „Fakulta inform“

Ověřit: federace přes dva endpointy

Wikidata se **9. 5. 2025 rozdělila na dva grafy** – vědecké články byly přes polovinu trojic a přestalo se to vejít na jeden stroj.

```
PREFIX wdsubgraph: <https://query.wikidata.org/subgraph/>

SELECT ?jmeno ?nar WHERE {
  VALUES ?clanek { wd:Q29164671 }
  ?clanek wdt:P50 ?autor .                # článek → autoři
  SERVICE wdsubgraph:wikidata_main {     # skok do druhého grafu
    ?autor wdt:P569 ?nar ; rdfs:label ?jmeno .
    FILTER(LANG(?jmeno) = "cs")
  }
}
```

```
Tim Berners-Lee 1955-06-08 | James Hendler 1957-04-02
```

Česká otevřená data

Na úvodní přednášce jsem tvrdil, že se u nás publikuje nejvíc v XML.

```
PREFIX dcat:<http://www.w3.org/ns/dcat#>
PREFIX dct:<http://purl.org/dc/terms/>

SELECT ?format
      (COUNT(DISTINCT ?d) AS ?n)
WHERE {
  ?d      a dcat:Dataset ;
         dcat:distribution ?dist .
  ?dist  dct:format ?format .
}
GROUP BY ?format
ORDER BY DESC(?n)
```

formát	sad	formát	sad
ZIP	11 890	JSON-LD	1 130
XML	11 782	GeoJSON	796
CSV	5 126	KML	714
JSON	1 823	HTML	581

Endpoint data.gov.cz/sparql

Katalog jako graf: vstup do projektu

URL ke stažení všech CSV o kvalitě ovzduší

```
PREFIX dcat:<http://www.w3.org/ns/dcat#>
PREFIX dct:  <http://purl.org/dc/terms/>

SELECT DISTINCT ?nazev ?url WHERE {
  ?ds    a dcat:Dataset ; dct:title ?nazev ; dcat:distribution ?dist .
  ?dist dcat:downloadURL ?url ; dct:format ?f .
  FILTER(STRENDS(STR(?f), "file-type/CSV"))
  FILTER(CONTAINS(LCASE(?nazev), "ovzduší"))
}
```

Kvalita ovzduší – aktuální hodinové údaje	opendata.chmi.cz/air_quality/
Kvalita ovzduší – data z mobilních stanic	data.brno.cz/api/download/...
Emise znečišťujících látek (REZZO 1–4)	data.csu.gov.cz/opendata/...

- Výstupem dotazu je **seznam URL** – ten rovnou pustíte do `curl` z minulé přednášky
- Metadata katalogu jsou graf; dotazují se tedy **na data o datech**

Transformace pomocí CONSTRUCT

```
PREFIX ex: <https://upa.fit.vut.cz/def#>

CONSTRUCT {
  ?obec ex:ruianKod ?ruian ; ex:nazev ?jmeno ;
        ex:pocetObyvatel ?obyvatel .
} WHERE {
  ?obec wdt:P31 wd:Q5153359 ; wdt:P7606 ?ruian ;
        wdt:P1082 ?obyvatel ; rdfs:label ?jmeno .
  FILTER(LANG(?jmeno) = "cs" && ?obyvatel > 20000)
}
```

- Výsledkem **není tabulka, ale graf** – přemapovaný na můj vlastní slovník
- Tento výstup nahraju do svého úložiště a dál se ptám jen na něj
- **ETL transformace**, zapsaná deklarativně

Kde to naráží

- **Timeouty a rate limity** – veřejný endpoint vám velký dotaz nedopočítá
- **Nerovnoměrné pokrytí** – Wikidata vědí o Brně všechno a o malé firmě nic
- **Kvalita** – historické hodnoty, chybějící kvalifikátory, volně použité [owl:sameAs](#)
- **Dostupnost** – endpoint je cizí server; dnes běží, zítra vrátí 502 (viz RÚIAN)
- Vždy lze dump **stáhnout a nahrát do lokálního úložiště**
 - Fuseki, Oxigraph, QLever (Ukládání a Příprava Dat :-)
 - Umožňuje propojit datasety v jednom úložišti (viz podgrafy)

A to je vše!

Dotazy?