



Ukládání a příprava dat

Úvod do předmětu – k čemu to je a jak to spolu souvisí

doc. Ing. Radek Burget, Ph.D.

burgetr@fit.vutbr.cz

Osnova předmětu

1. Extrakce dat z webu
2. Sémantický web a propojená data
3. Porozumění datům, vizualizace, korelace
4. Předzpracování I: čištění, integrace
5. Předzpracování II: redukce, transformace
6. Objektový přístup v databázích
7. NoSQL I: CAP a BASE, klíč-hodnota
8. *Půlsemestrální zkouška*
9. NoSQL II: sloupcové, dokumentové, grafové
10. Jazyky a systémy, případové studie
11. XML a JSON v databázích
12. Prostorové databáze
13. Indexování vícedimenzionálních dat

Nejčastější stížnost

„Je to spousta nesouvisejících témat. Nedá se to nijak propojit.“

- Je to pochopitelné
- a **není to pravda**
- Jaký je záměr a souvislosti?

Rozvržení předmětu

1. Jak data získat a připravit

přednášky 1 až 5

- 1 Extrakce dat z webu (web scraping)
- 2 Sémantický web a propojená data
- 3 Porozumění datům, vizualizace, korelace
- 4 Předzpracování I: čištění dat, integrace
- 5 Předzpracování II: redukce, transformace

Projekty 1 a 2

získání dat → příprava → popisné charakteristiky

Projekt 3

optimální způsob uložení rozsáhlých dat

2. Kam data uložit a jak se na ně ptát

přednášky 6 až 13

- 6 Objektový přístup v databázích
- 7 NoSQL I – CAP a BASE, klíč-hodnota
- 8 *Půlsemestrální zkouška*
- 9 NoSQL II – sloupcové, dokumentové, grafové
- 10 Jazyky a systémy, případové studie
- 11 XML a JSON v databázích
- 12 Prostorové databáze
- 13 Indexování vícedimenzionálních dat

Mimoходом: název předmětu

- Předmět se jmenuje **Ukládání a příprava dat**
- Učíme to **v opačném pořadí**, než jak zní název
 - Nejdřív příprava, potom ukládání
- A je to tak správně – **v tom pořadí se to v praxi děje**
- Jedno bez druhého nemůže existovat
 - Ukládání bez přípravy je **skládka**
 - Příprava bez ukládání je **jednorázový skript**, který nikdo nezopakuje


Osoby a obsazení

- [doc. Ing. Radek Burget, Ph.D.](#) (garant)
 - Web scraping, propojená data
- [Ing. Ivana Burgetová, Ph.D.](#)
 - Porozumění datům, předzpracování
- [RNDr. Marek Rychlý, Ph.D.](#) (organizace, přihlašování, atd.)
 - Pokročilé databáze
- [doc. Dr. Ing. Dušan Kolář](#)
 - Prostorové databáze, indexování vícedimenzionálních dat

Příprava dat

Jak data získat a připravit. Přednášky 1 až 5.

Cesta dat



první polovina UPA

60 až 80 % reálného času práce s daty

jiné předměty

Kde končí UPA

- Modelování a získávání znalostí učí **jiné předměty** (ZZN, SFC, SUI)
- UPA je všechno **před** modelem
- Což je v praxi **60 až 80 % času** práce s daty
 - Sexy část je ten zbytek :-)

Data jsou připravena, ale...

- Nepravidelná a měnící se struktura
- Vztahy jsou součástí obsahu
- Chybějící a neúplné atributy
- Souřadnice, geometrie, časové řady
- Objem, který se nevejde na jeden stroj

Dáte tohle do relační tabulky?

- Zbytek semestru je odpověď na tuhle otázku

Ukládání dat

Kam data uložit a jak se na ně ptát. Přednášky 6 až 13.

Předpoklady, na kterých stojí relační model

Předpoklad z IDS	Kdy neplatí	Přednáška
Data jsou plochá a skalární	objekty, kolekce, dědičnost	Objektový přístup
Data se vejdou na jeden stroj	distribuce, výpadky	NoSQL I – CAP, BASE
Schéma znám dopředu a je pevné	heterogenní, měnící se data	NoSQL II, XML a JSON
Vztahy jsou vzácné, řeším je JOINem	vztah je ten hlavní obsah	grafové modely
Ptám se na rovnost nebo rozsah v 1D	„blízko“, „uvnitř“, podobnost	prostorové db, indexování

- **Systematické představení návrhového prostoru**
- Jaké máme možnosti, když předpoklady s IDS neplatí?

Všechno je kompromis

- Neexistuje nejlepší databáze ani nejlepší postup
- Existuje jen **volba a její cena**

Chci	Platím
Dostupnost při výpadku sítě	Konzistencí (CAP)
Rychlý dotaz	Redundancí a denormalizací
Volnost ve struktuře dat	Kontrolou, kterou by odvedlo schéma
Zpracovatelný objem	Přesností (vzorkování, agregace)
Rychlé hledání podobnosti	Přesností výsledku a pamětí na index

K čemu to celé je

„Máme tahle data a tenhle způsob přístupu k nim.
Kam to uložíme a co s tím musíme udělat předtím?“

- Tuhle otázku dostanete na pohovoru na **každou datovou nebo backendovou pozici**
- Po UPA na ni umíte odpovědět – a umíte i **zdůvodnit, co tím ztrácíte**
- Když vám kdykoli během semestru nebude jasné, proč zrovna tohle, **zeptejte se**
 - Je to legitimní otázka a má odpověď

Volba technologií

„Nechápu obsesi na této fakultě s XML. Nadával jsem na to už v IIS, vyhodíte to dvěři, vleze to zase zpátky oknem. Nevím, co v praxi dělám špatně, ale na XML jsem zatím nenarazil ani omylem.“

- data.gov.cz, katalog českých otevřených dat
 - XML: 11 tis. datových sad, CSV: 5 tis., JSON < 2 tis.
 - JSON-LD, Turtle, SPARQL endpoint
- volby.cz (XML)
- data.europa.eu
 - CSV: 270 tis., JSON 87 tis., XML 82 tis.

Volba technologií (II)

Chceme učit přenositelné principy, konkrétním technologiím se ale vyhnout nelze.

1. Pragmatická volba

- Znalost určitých standardů (vč. XML) se od absolventa FIT očekává
- Technologie (byť překonaná) je široce používána

2. Ideologická volba

- Existující problém má **elegantní** a **v praxi ověřené** řešení, jen o něm **řadoví ajťáci** neví
- Absolvent FIT má přicházet s lepšími řešeními.

A to je vše!

Veškeré materiály jsou / budou v E-learning VUT (Moodle)

Dotazy?